

МЕТОД К БЛИЖАЙШИХ СОСЕДЕЙ

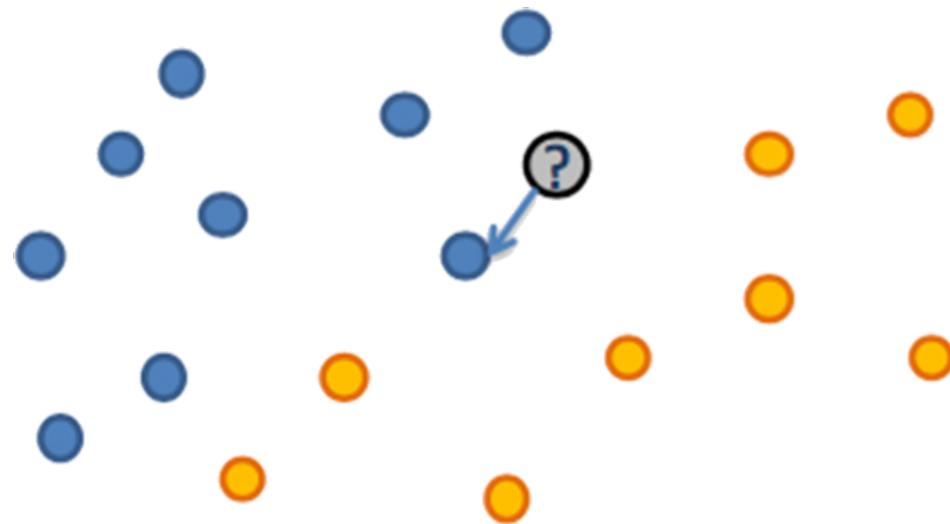
МЕТРИЧЕСКИЕ АЛГОРИТМЫ

- › Метрические алгоритмы: в пространстве признаков введено понятие метрики
- › Начнём с метода ближайшего соседа в задаче классификации

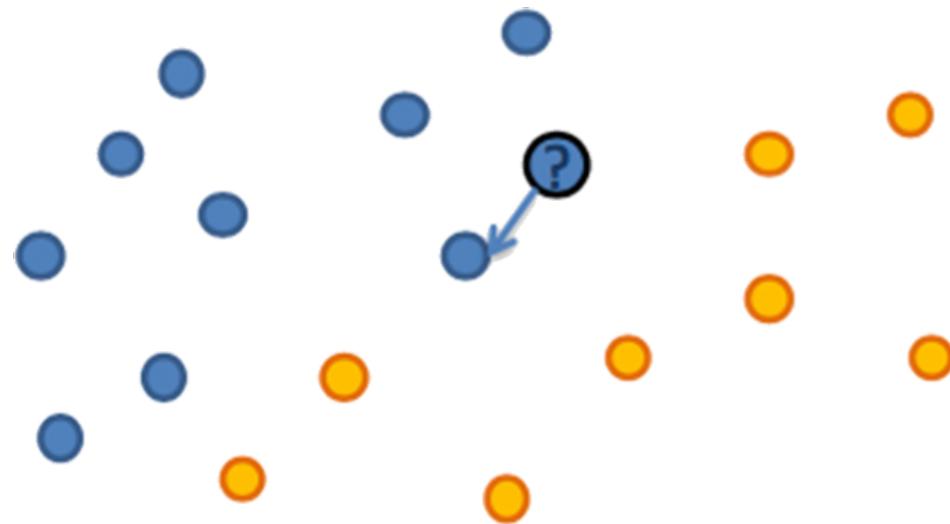
МЕТОД БЛИЖАЙШЕГО СОСЕДА



МЕТОД БЛИЖАЙШЕГО СОСЕДА

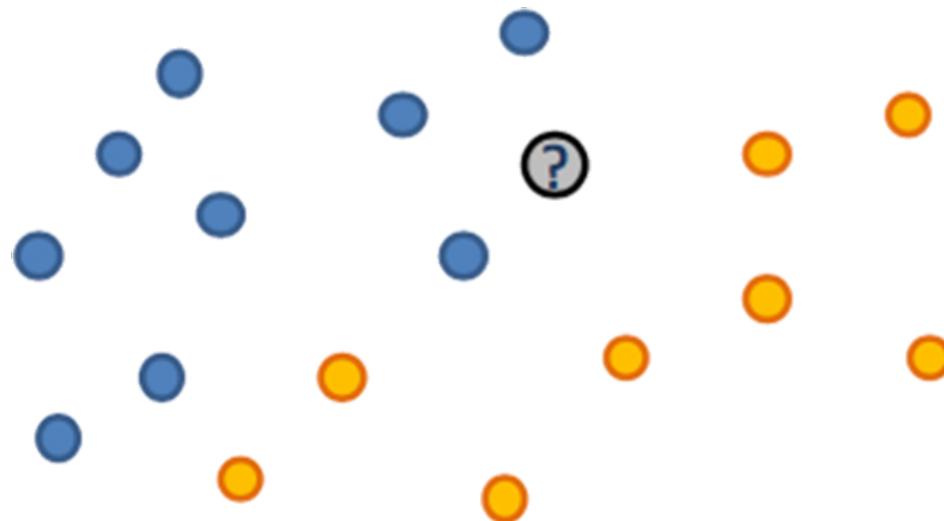


МЕТОД БЛИЖАЙШЕГО СОСЕДА



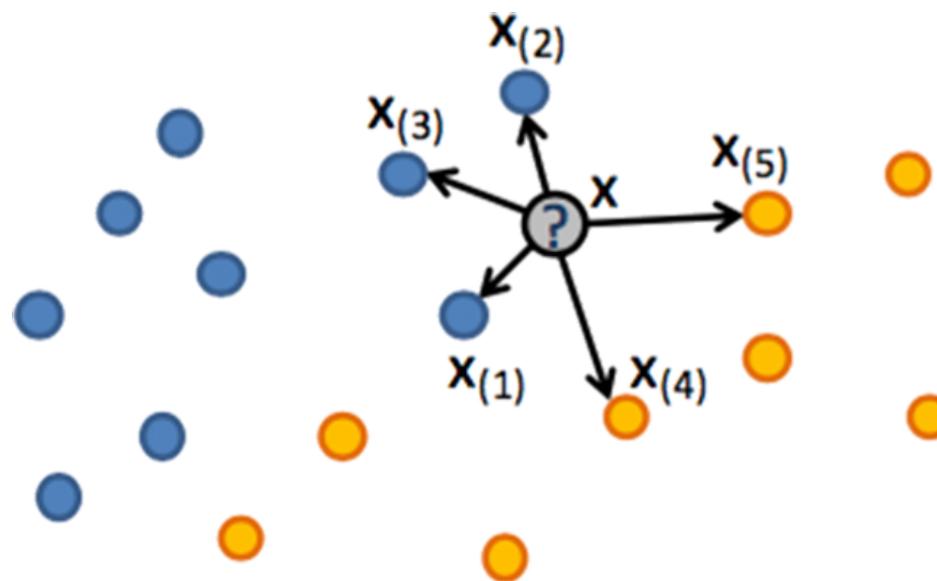
МЕТОД К БЛИЖАЙШИХ СОСЕДЕЙ (KNN)

Пример классификации ($k = 5$)



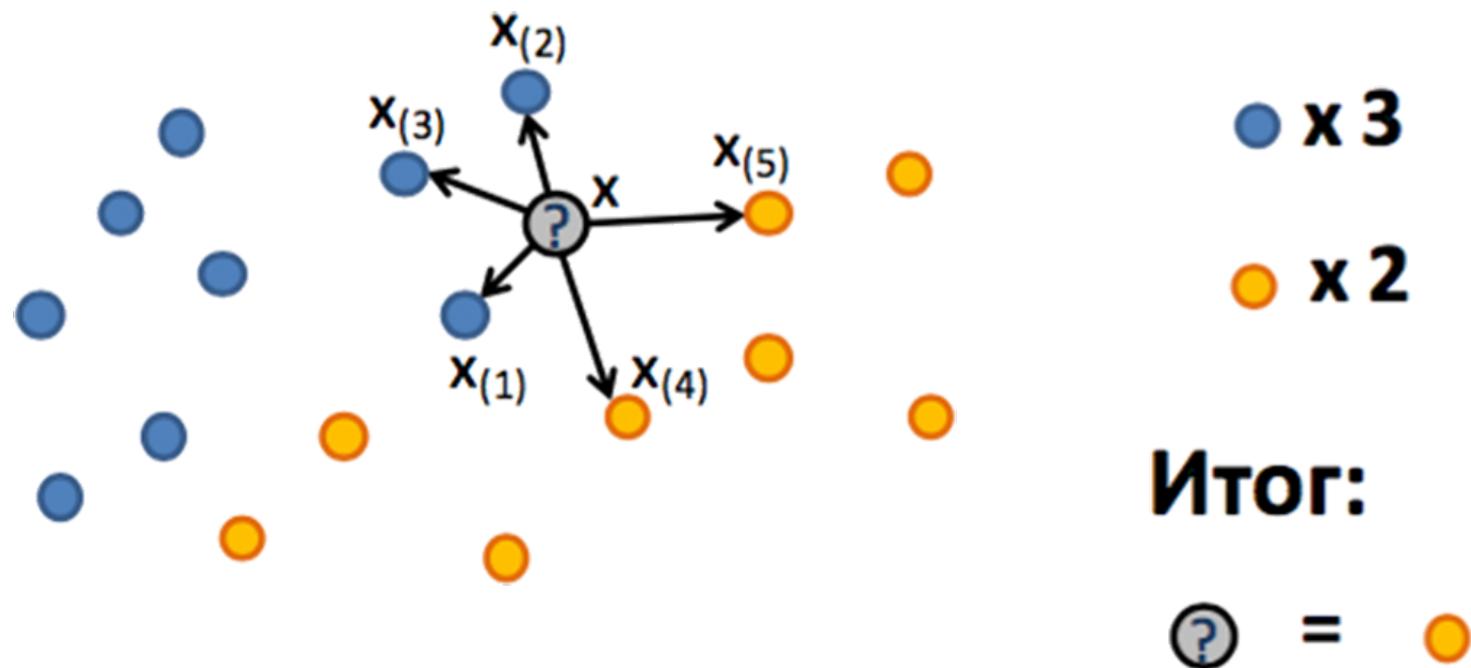
МЕТОД К БЛИЖАЙШИХ СОСЕДЕЙ (KNN)

Пример классификации ($k = 5$)



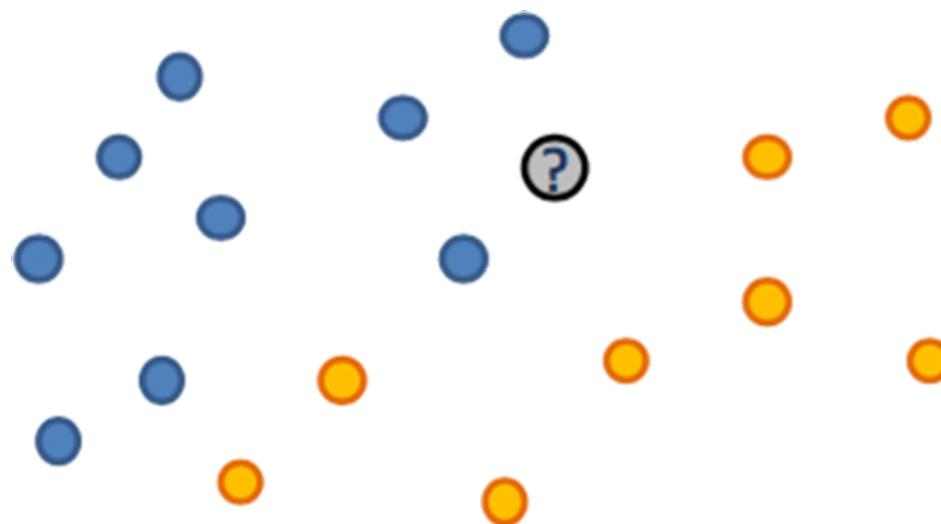
МЕТОД К БЛИЖАЙШИХ СОСЕДЕЙ (KNN)

Пример классификации ($k = 5$)



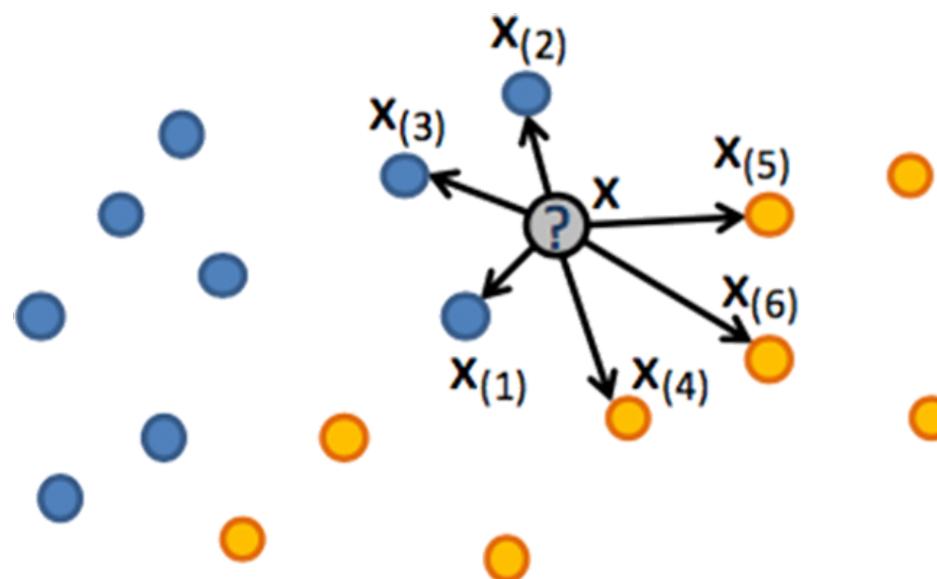
ВЗВЕШЕННЫЙ KNN

Пример классификации ($k = 6$)



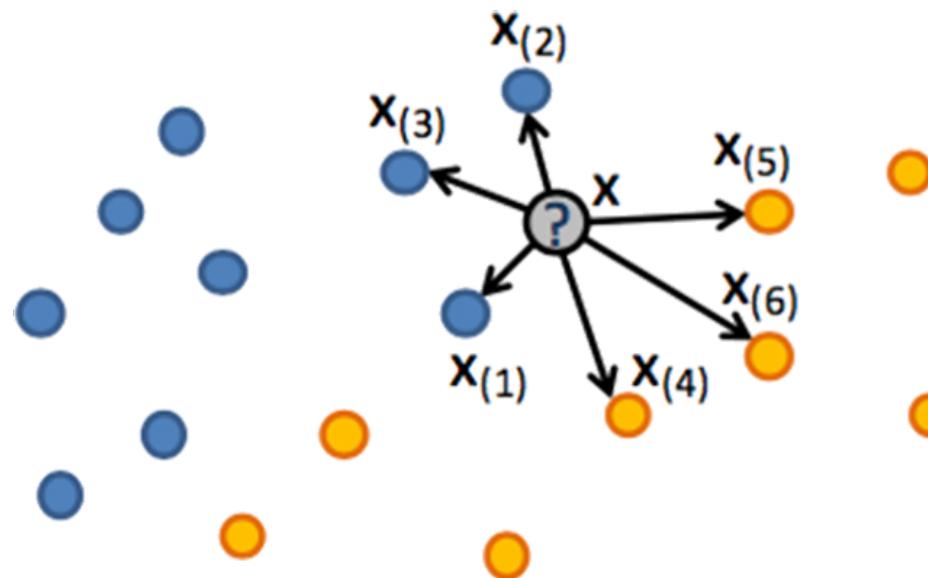
ВЗВЕШЕННЫЙ KNN

Пример классификации ($k = 6$)



ВЗВЕШЕННЫЙ KNN

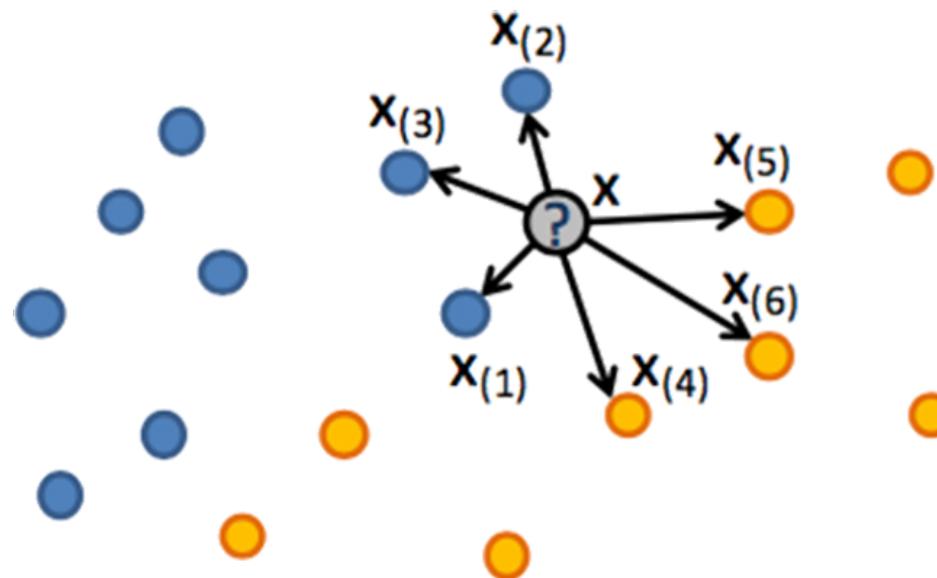
Пример классификации ($k = 6$)



Веса можно определять как функцию от соседа или его номера: $w(x_{(i)}) = w(i)$

ВЗВЕШЕННЫЙ KNN

Пример классификации ($k = 6$)

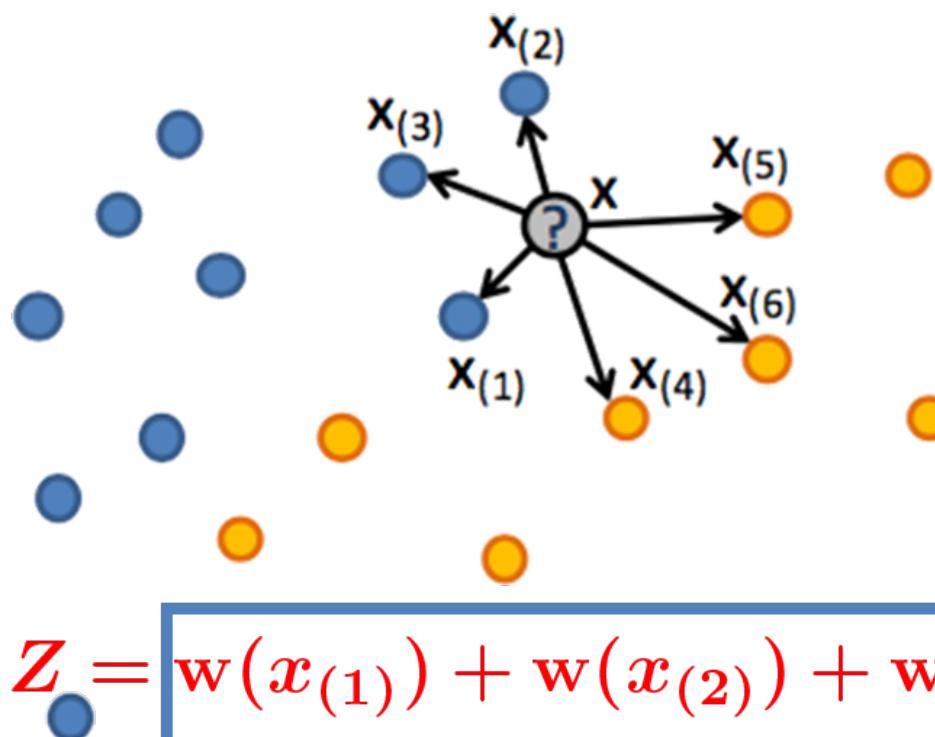


Веса можно определять как функцию от соседа или его номера: $w(x_{(i)}) = w(i)$
Или как функцию расстояния:

$$w(x(i)) = w(d(x, x_{(i)}))$$

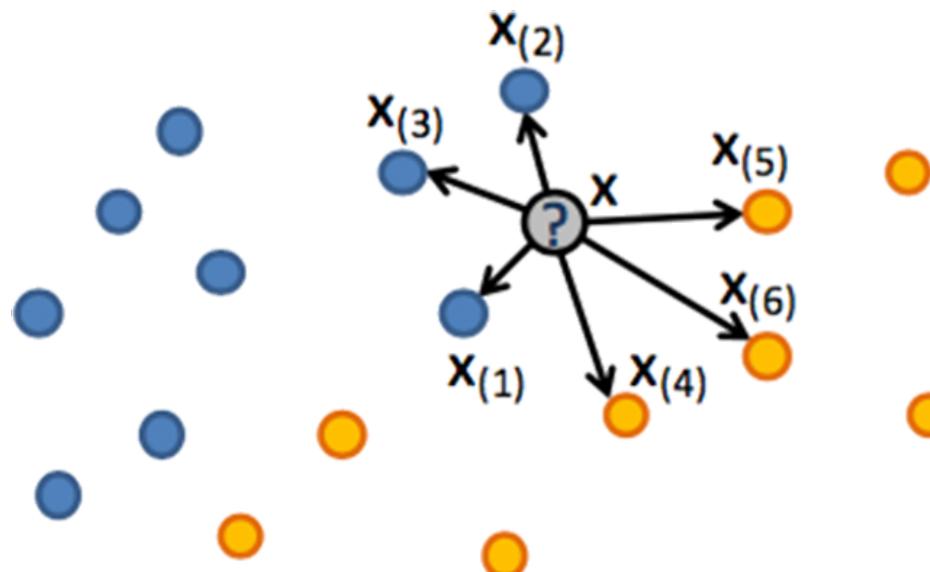
ВЗВЕШЕННЫЙ KNN

Пример классификации ($k = 6$)



ВЗВЕШЕННЫЙ KNN

Пример классификации ($k = 6$)

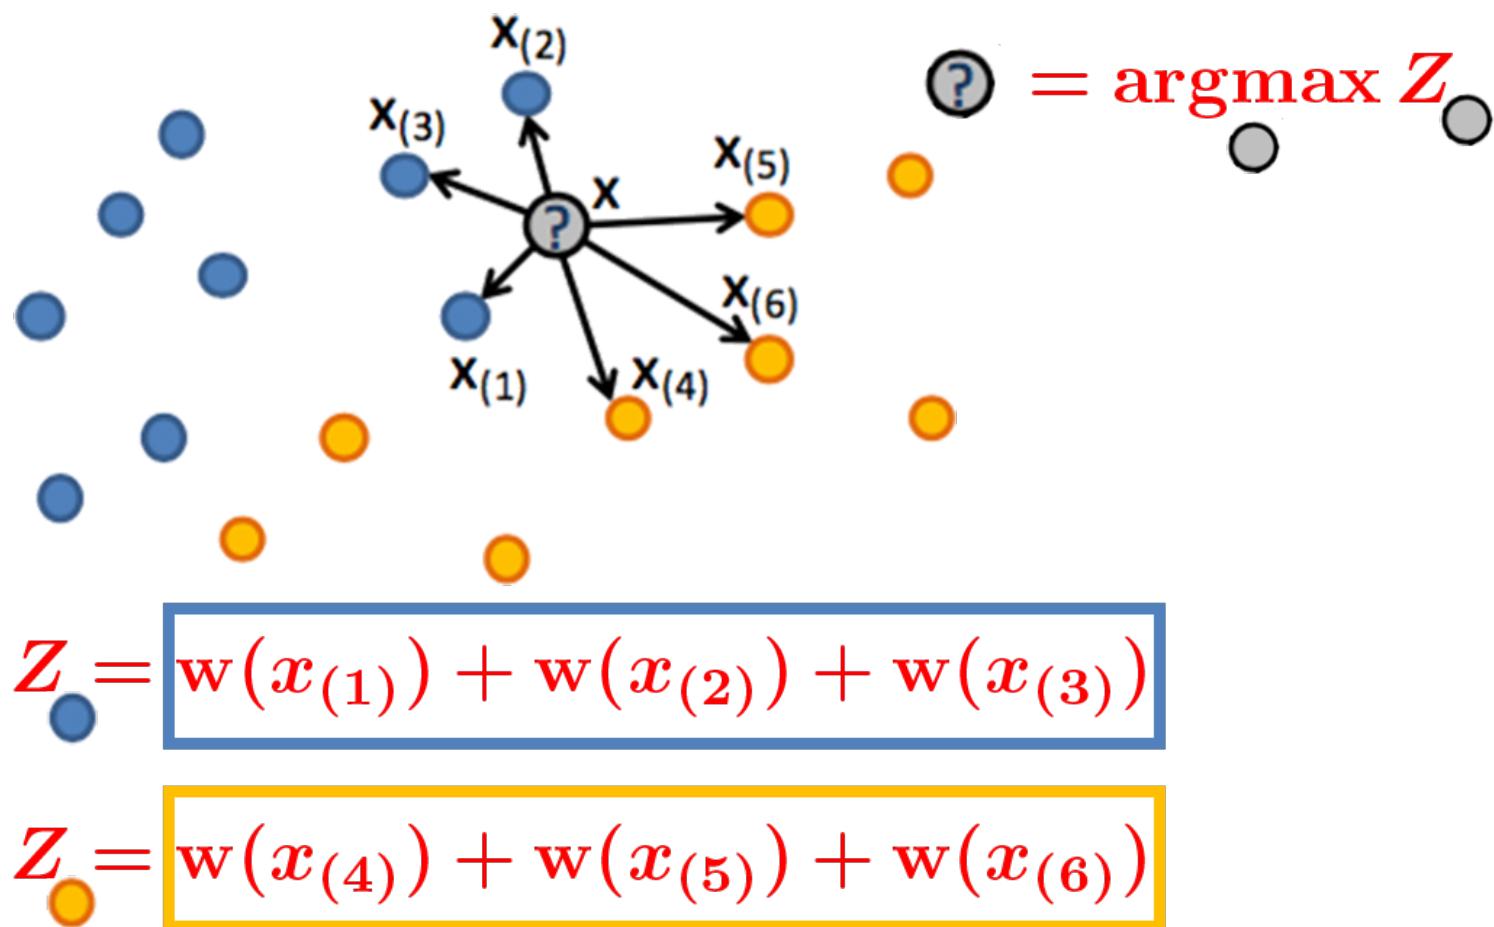


$$Z = w(x_{(1)}) + w(x_{(2)}) + w(x_{(3)})$$

$$Z = w(x_{(4)}) + w(x_{(5)}) + w(x_{(6)})$$

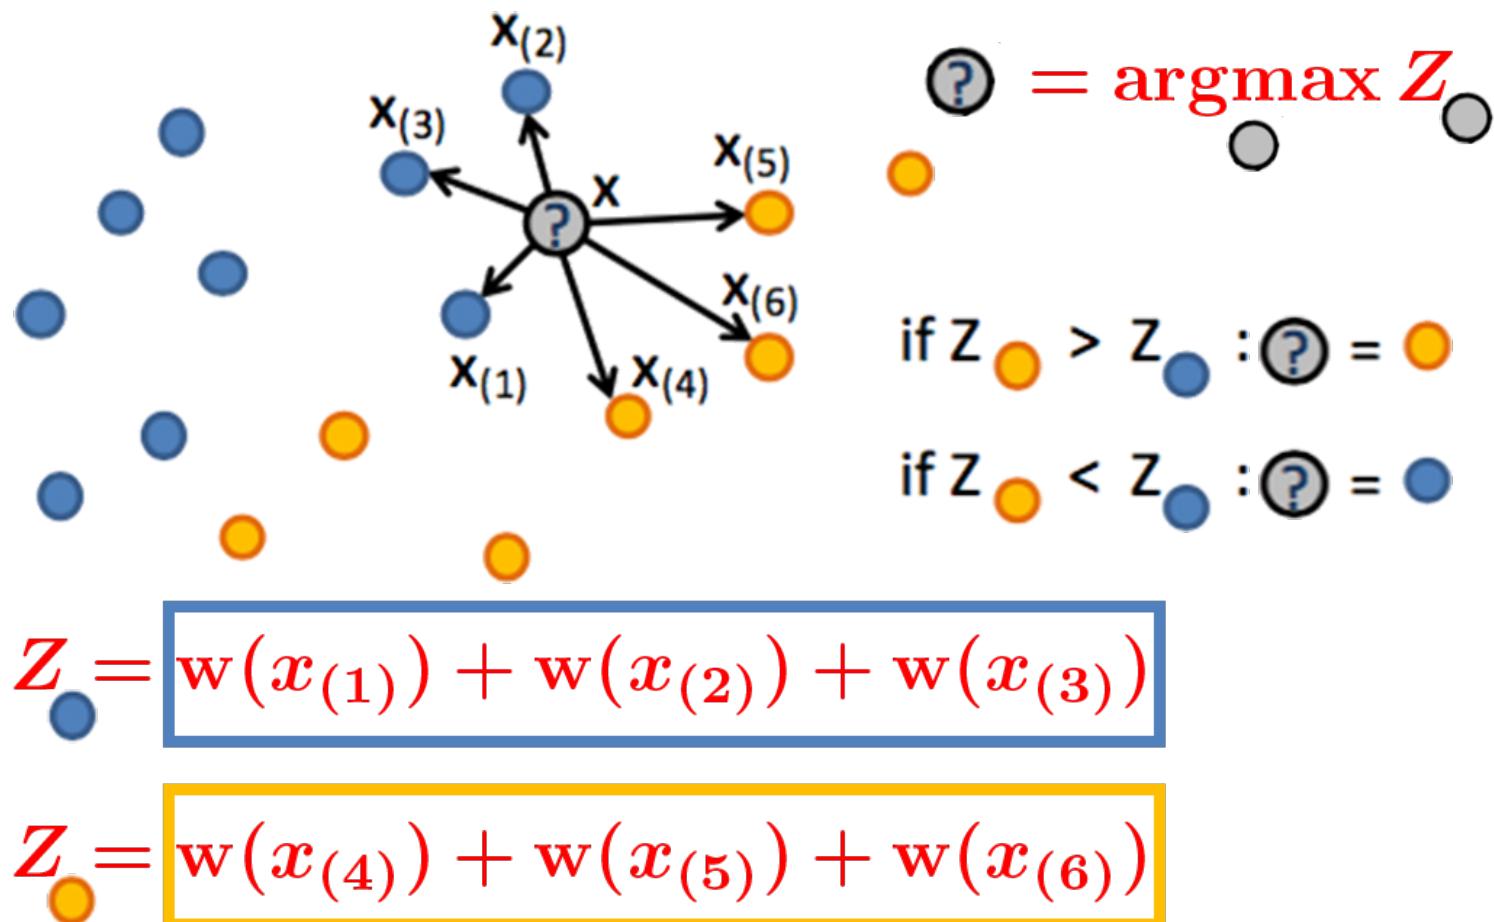
ВЗВЕШЕННЫЙ KNN

Пример классификации ($k = 6$)



ВЗВЕШЕННЫЙ KNN

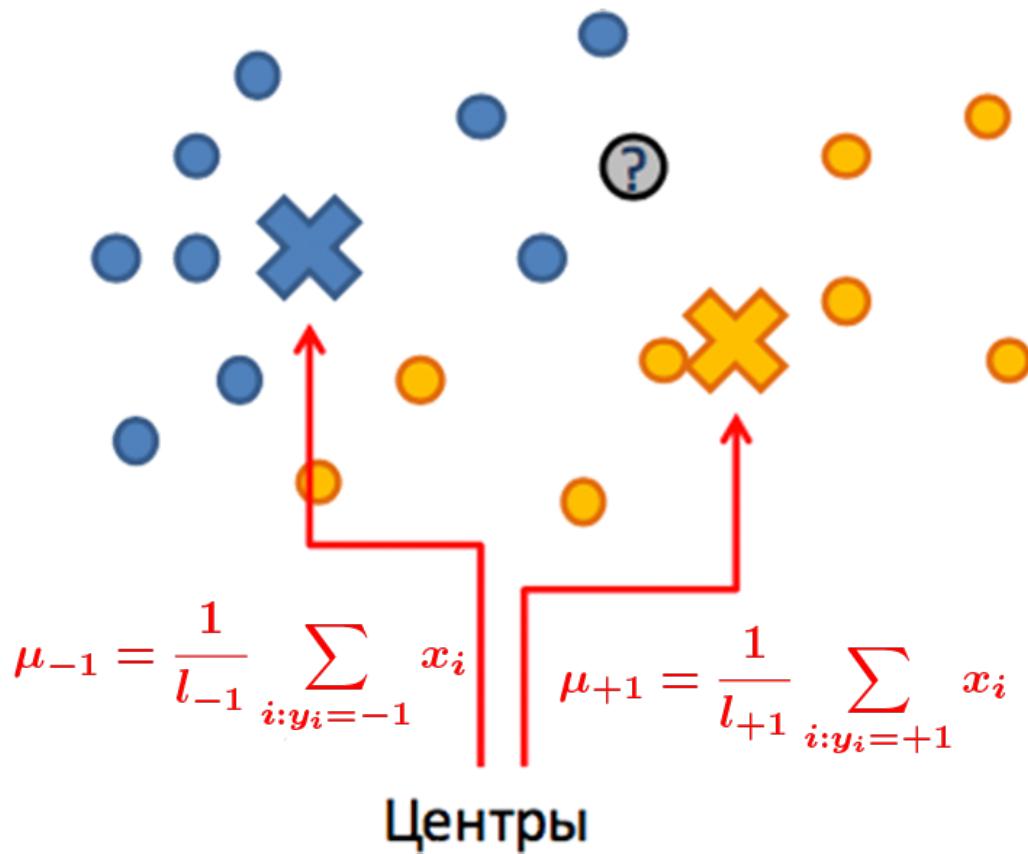
Пример классификации ($k = 6$)



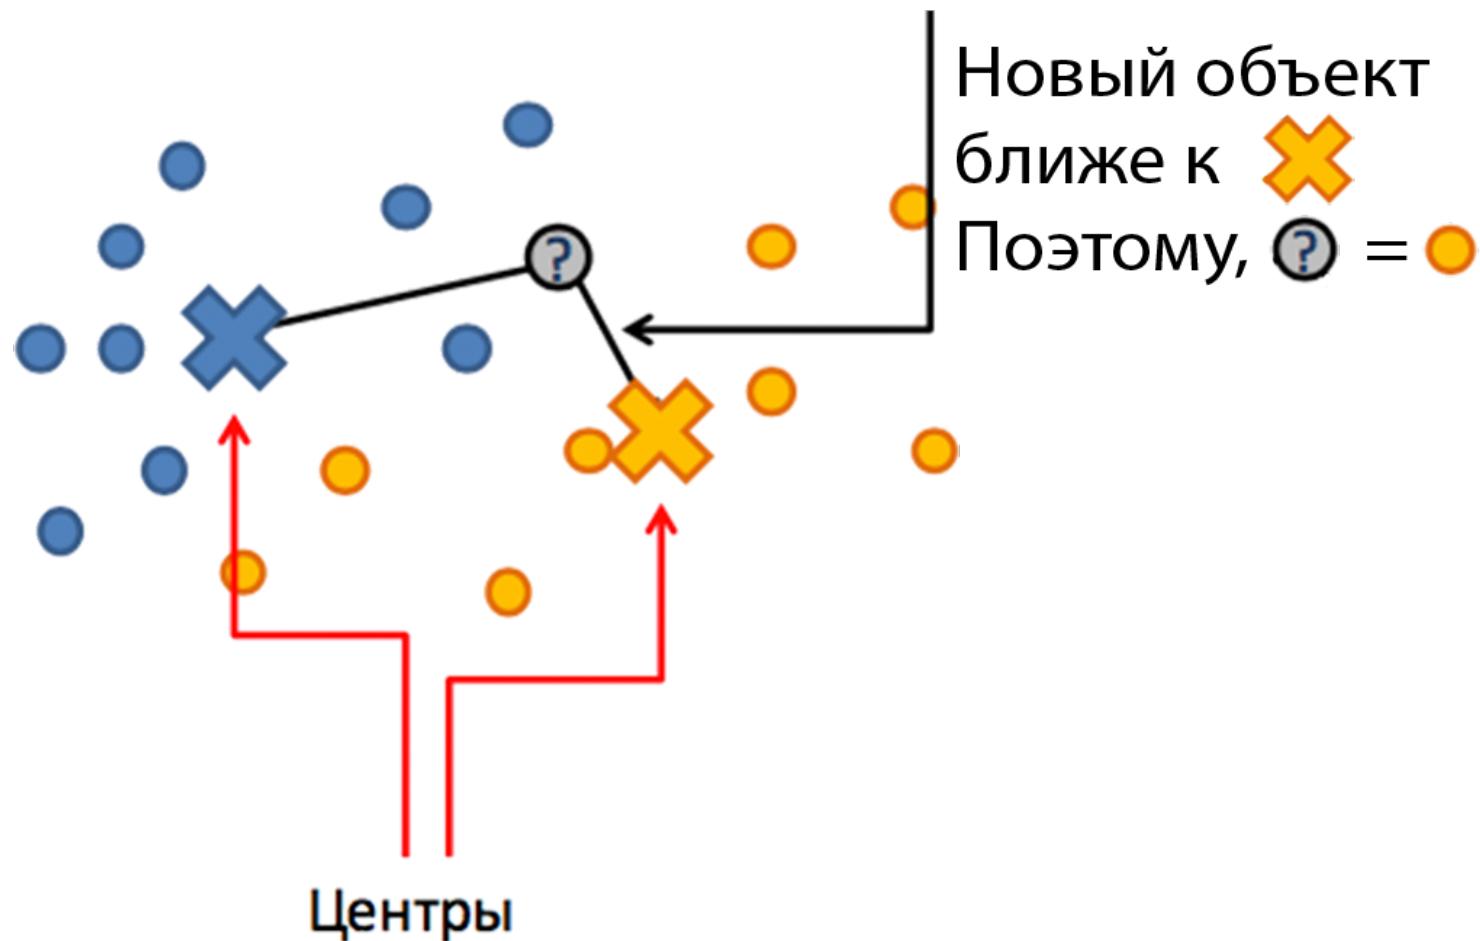
ЦЕНТРОИДНЫЙ КЛАССИФИКАТОР



ЦЕНТРОИДНЫЙ КЛАССИФИКАТОР

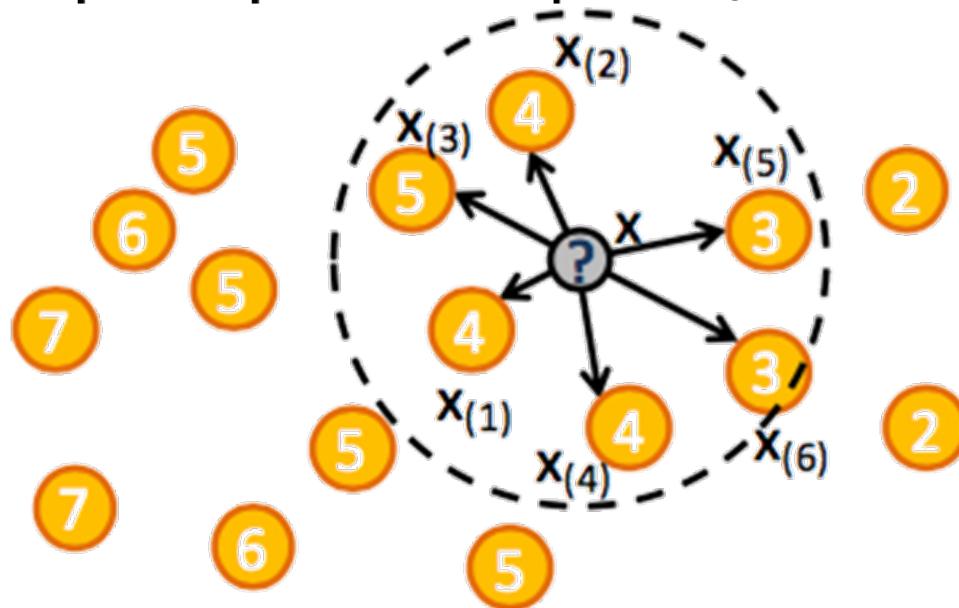


ЦЕНТРОИДНЫЙ КЛАССИФИКАТОР



ВЗВЕШЕННЫЙ KNN ДЛЯ РЕГРЕССИИ

Пример классификации ($k = 6$)

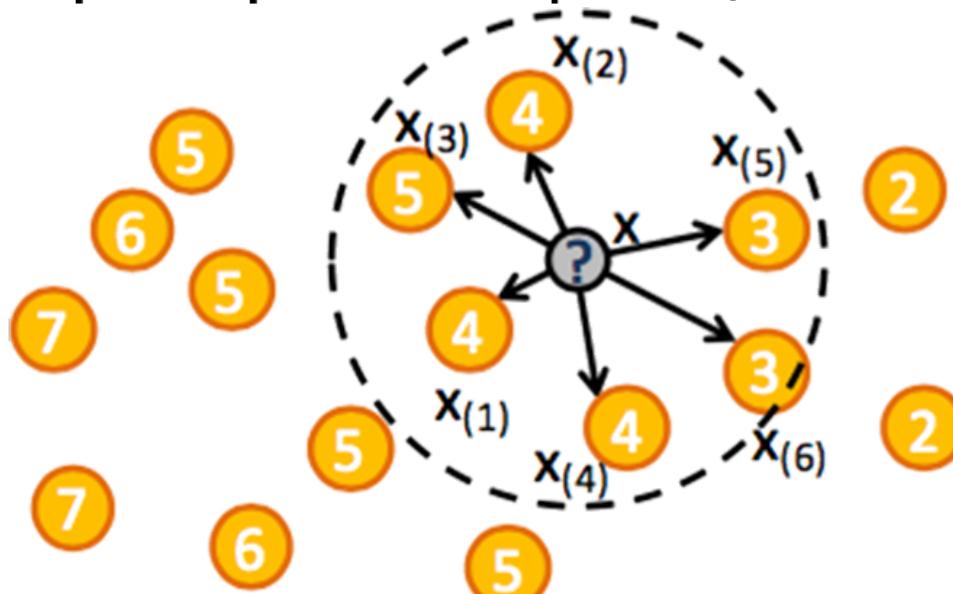


Веса можно определять как функцию от соседа или его номера: $w(x_{(i)}) = w(i)$
Или как функцию расстояния:

$$w(x(i)) = w(d(x, x_{(i)}))$$

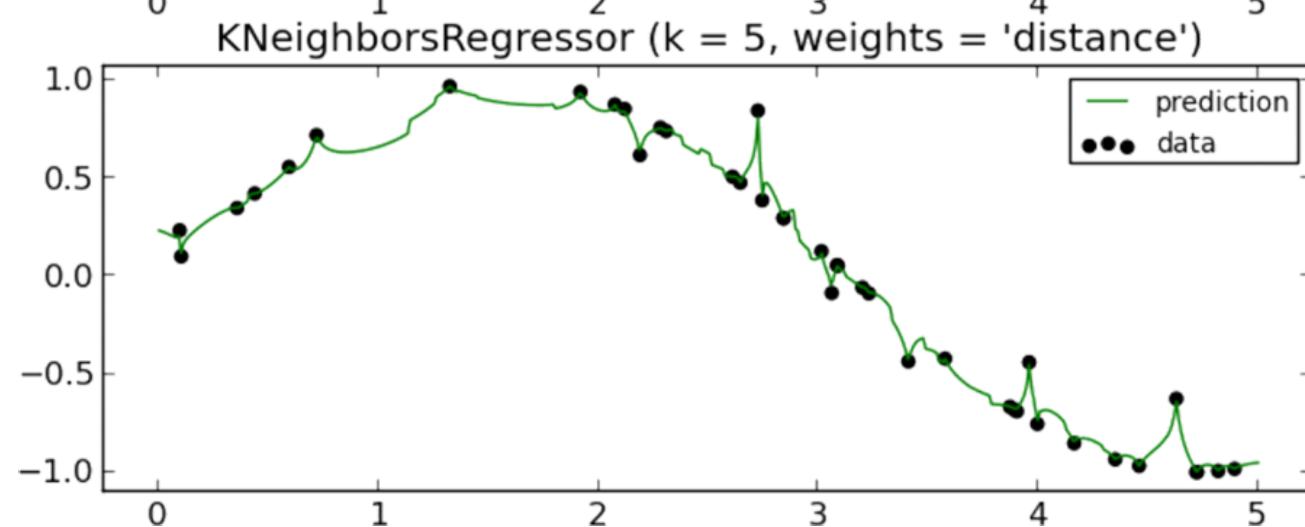
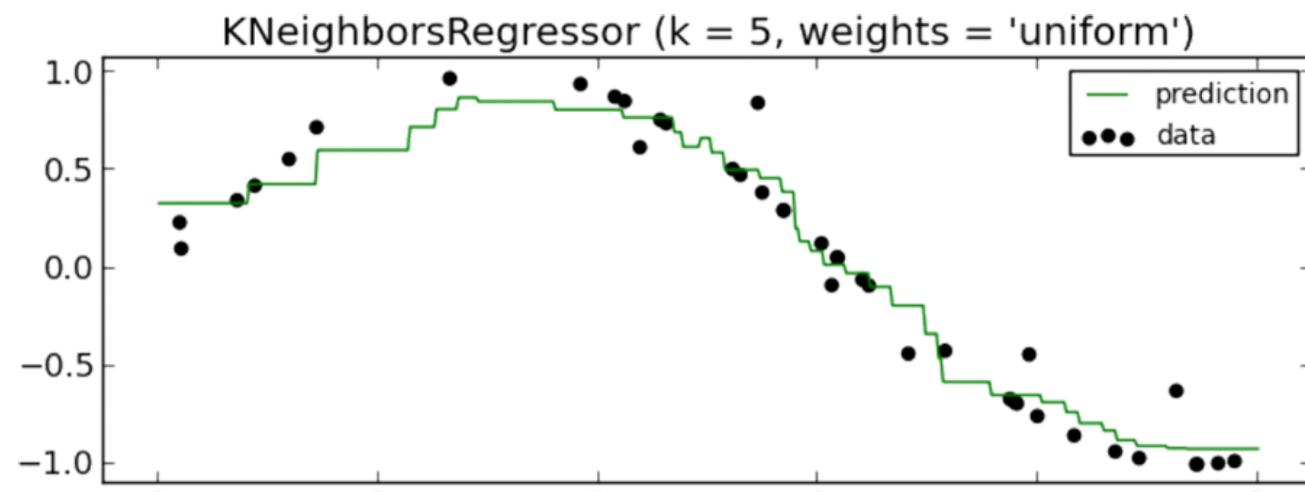
ВЗВЕШЕННЫЙ KNN ДЛЯ РЕГРЕССИИ

Пример классификации ($k = 6$)



$$\begin{aligned} \textcircled{?} &= \frac{4 w(x_{(1)}) + 4 w(x_{(2)}) + 5 w(x_{(3)}) +}{w(x_{(1)}) + w(x_{(2)}) + w(x_{(3)}) +} \\ &\quad + \frac{4 w(x_{(4)}) + 3 w(x_{(5)}) + 3 w(x_{(6)})}{w(x_{(4)}) + w(x_{(5)}) + w(x_{(6)})} \end{aligned}$$

ВЫБОР ВЕСОВ В KNN



ВЫБОР ВЕСОВ В KNN

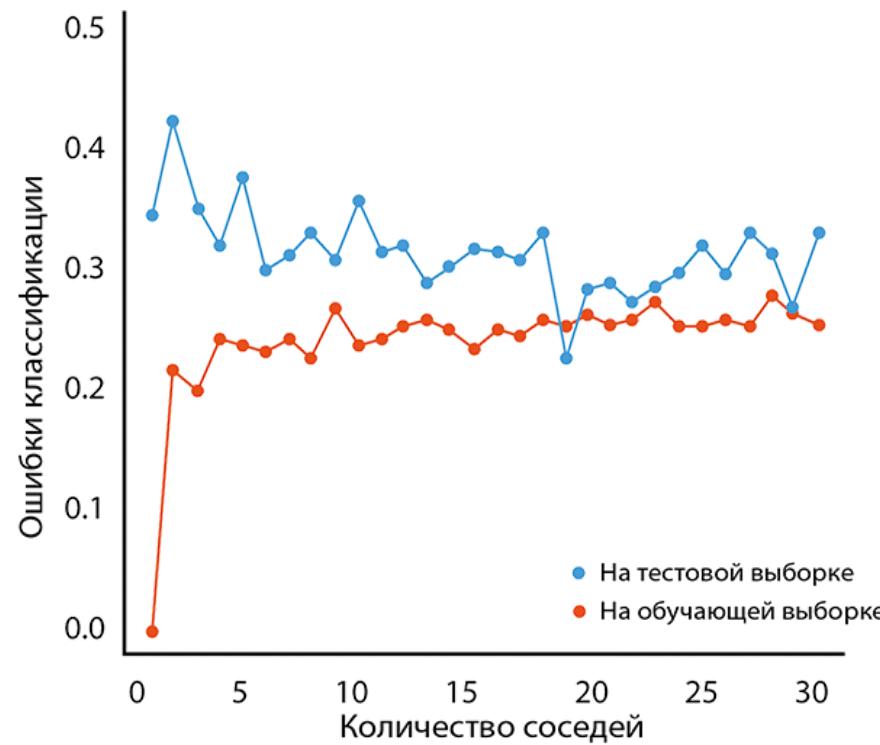
- › Метод k ближайших соседей
- › Веса соседей
- › kNN в задаче классификации и в задаче регрессии

НАСТРОЙКА ПАРАМЕТРОВ В kNN

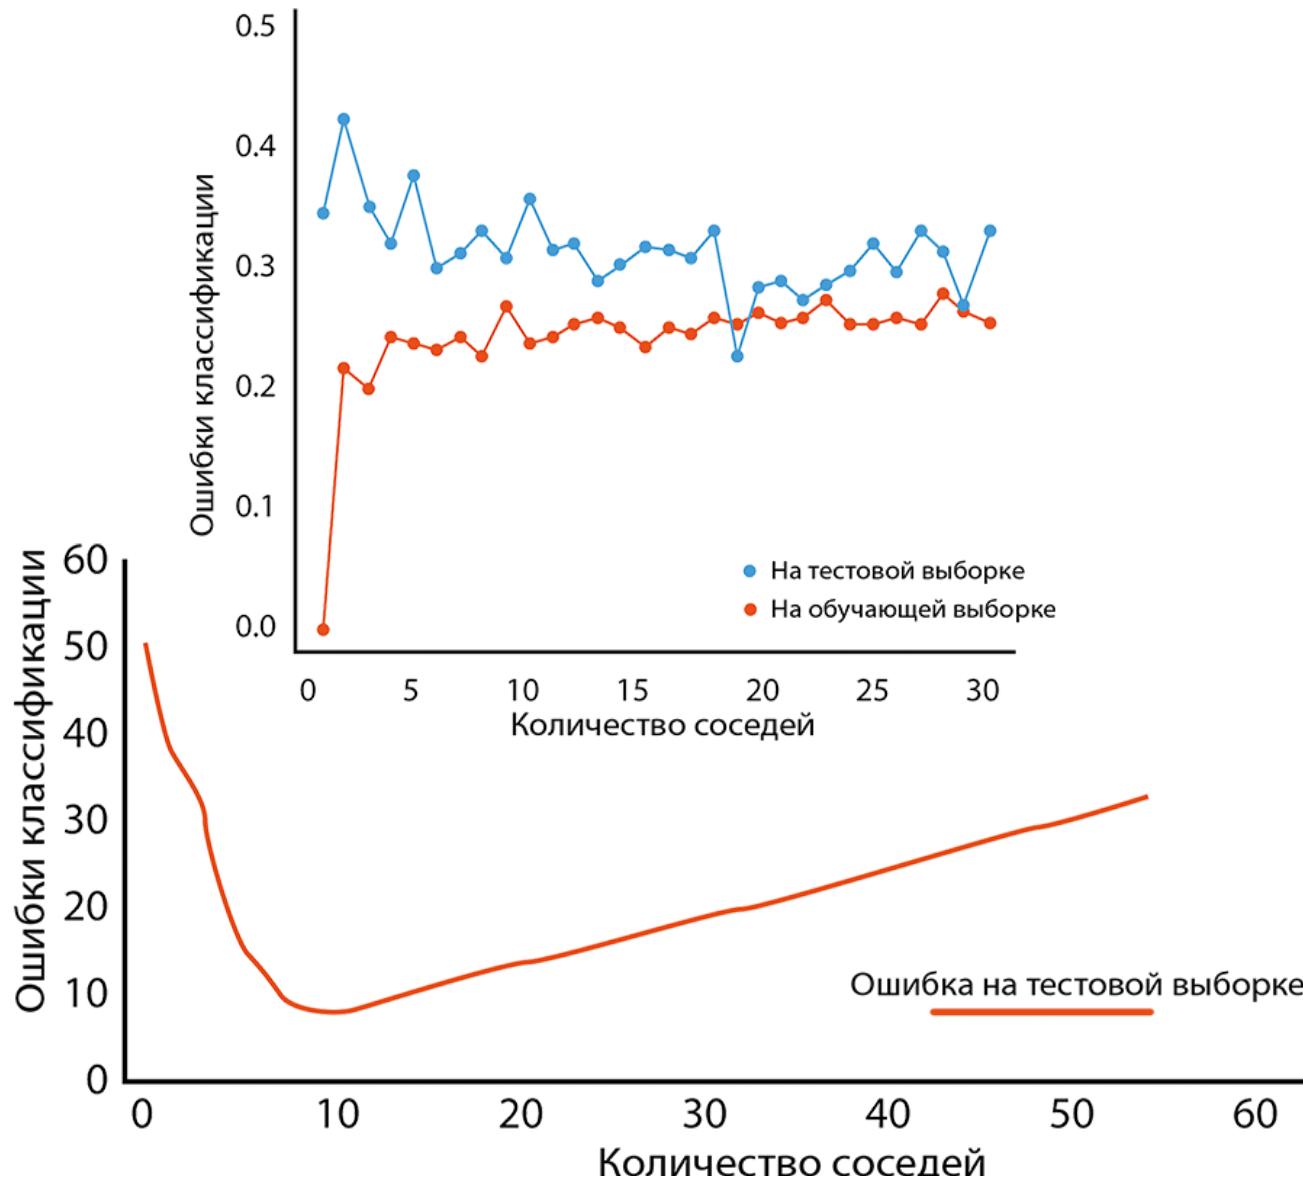
НАСТРОЙКА ПАРАМЕТРОВ В kNN

- › У kNN нет параметров, настраиваемых на обучающей выборке
- › Но есть параметры, выбираемые исследователем
- › Количество соседей, веса объектов и расстояние
- › Эти параметры можно подобрать

КОЛИЧЕСТВО СОСЕДЕЙ



КОЛИЧЕСТВО СОСЕДЕЙ



ВЕСА СОСЕДЕЙ КАК ФУНКЦИЯ ОТ НОМЕРА

- » $w(i)$ должна не возрастать
- » Простейший вариант: $w(i) = 1$
- » $w(i) = q^i, \ 0 < q < 1$
- » $w(i) = \frac{1}{i}, \ w(i) = \frac{1}{i+a}, \ w(i) = \frac{1}{(i+a)^b}$
- » Не очень удачный вариант: $w(i) = 1 - \frac{i-1}{k}$

ВЕСА СОСЕДЕЙ КАК ФУНКЦИЯ ОТ РАССТОЯНИЯ

» $w(d) = 1$

» $w(d) = \frac{1}{d}$

ВЕСА СОСЕДЕЙ КАК ФУНКЦИЯ ОТ РАССТОЯНИЯ

- » $w(d) = 1$
- » $w(d) = \frac{1}{d}$
- » $w(d) = \frac{1}{(q+a)^b}$
- » $w(d) = q^d, 0 < q < 1$
- » Ядра

ВЕСА СОСЕДЕЙ КАК ФУНКЦИЯ ОТ РАССТОЯНИЯ

- › В kNN можно настраивать количество соседей, функции весов объектов и метрику
- › Делать это нужно не на обучающей выборке, а по качеству в кросс-валидации
- › Уже обсудили: выбор количества соседей и весов объектов
- › Далее: метрики

МЕТРИКИ

ЧТО ТАКОЕ РАССТОЯНИЕ?

- › $\rho(x, y) \geq 0$
- › $\rho(x, y) = \rho(y, x)$
- › $\rho(x, y) \leq \rho(x, z) + \rho(z, y)$

ЧТО ТАКОЕ РАССТОЯНИЕ?

- › $\rho(x, y) \geq 0$
- › $\rho(x, y) = \rho(y, x)$
- › $\rho(x, y) \leq \rho(x, z) + \rho(z, y)$
- › Для нас это не важно, главное — чтобы работало

САМОЕ ОБЫЧНОЕ РАССТОЯНИЕ

› Евклидова метрика:

$$\rho(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

МЕТРИКА МИНКОВСКОГО

» Евклидова метрика:

$$\sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

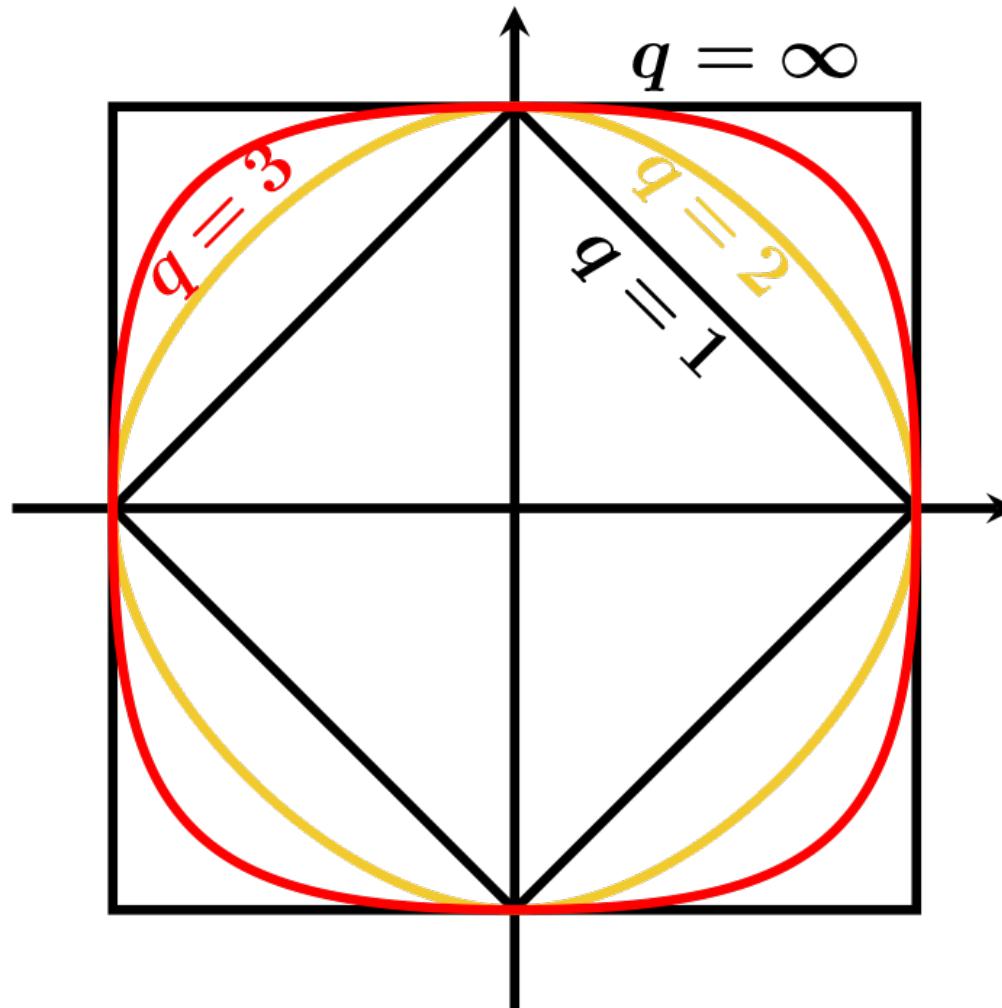
» Манхэттенская метрика:

$$\sum_{i=1}^n |x_i - y_i|$$

» Метрика Минковского:

$$\left(\sum_{i=1}^n (|x_i - y_i|)^q \right)^{\frac{1}{q}}$$

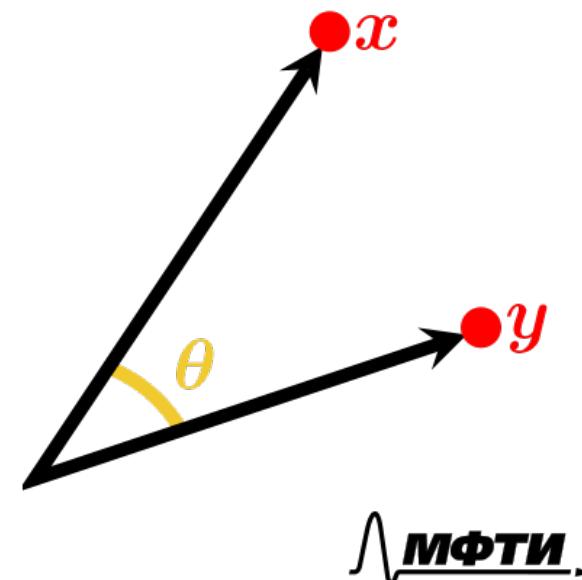
КАК «ПОСМОТРЕТЬ» НА МЕТРИКУ



КОСИНУСНАЯ МЕРА

$$\text{similarity} = \cos(\theta) = \frac{x \cdot y}{\|x\| \cdot \|y\|} = \frac{\sum_{i=1}^n x_i y_i}{\sqrt{\sum_{i=1}^n x_i^2} \sqrt{\sum_{i=1}^n y_i^2}}$$

➤ Функция близости, а не расстояние



КОЭФИЦИЕНТ КОРРЕЛЯЦИИ

$$r = \frac{\sum_{i=1}^n ((x_i - \bar{x})(y_i - \bar{y}))}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

ДРУГИЕ ФУНКЦИИ БЛИЗОСТИ

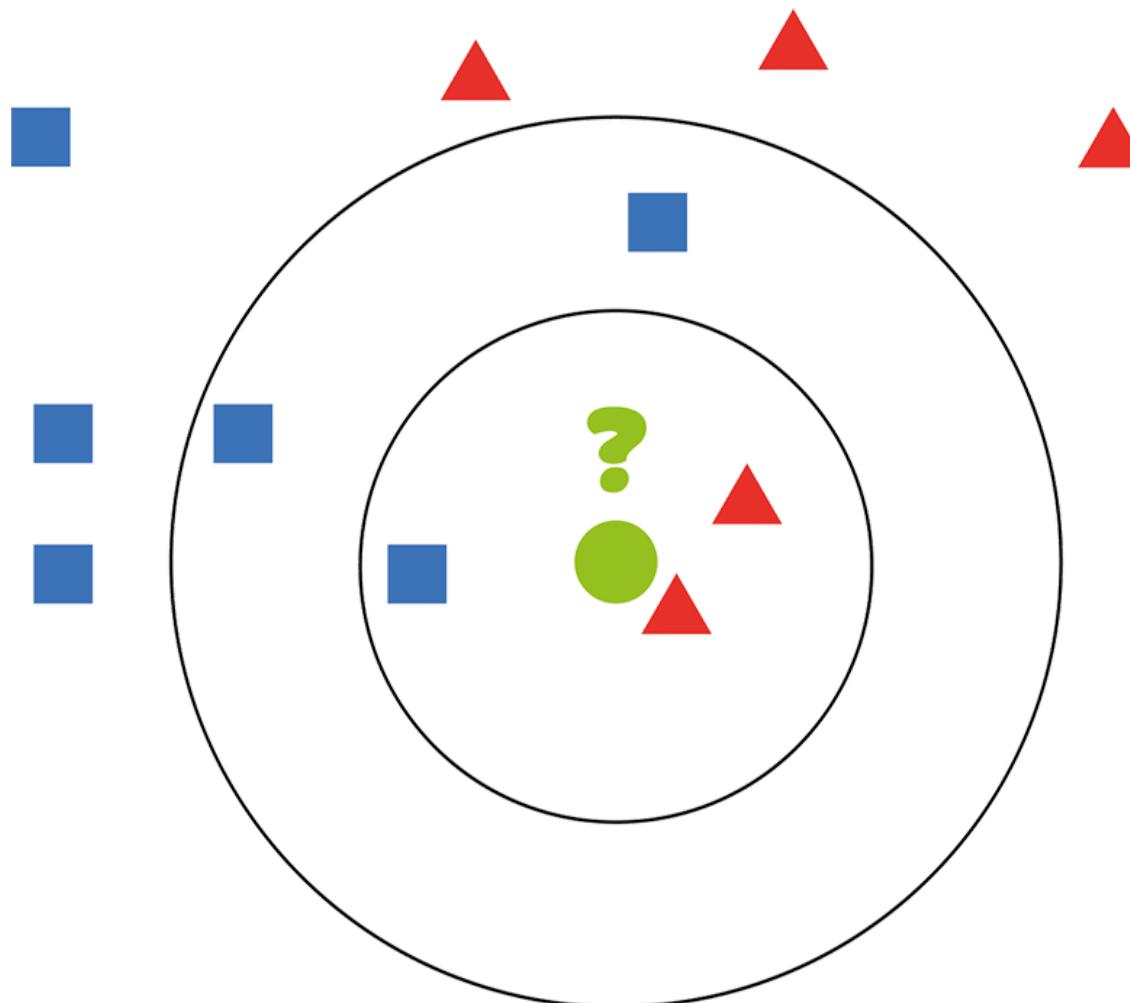
- » Скалярное произведение: $\sum x_i \cdot y_i$
- » Коэффициент Дайса: $\frac{2 \sum x_i \cdot y_i}{\sum x_i^2 + \sum y_i^2}$
- » Косинусная мера: $\frac{\sum x_i \cdot y_i}{\sqrt{\sum x_i^2} \cdot \sqrt{\sum y_i^2}}$
- » Коэффициент Жаккара: $\frac{\sum x_i \cdot y_i}{\sum x_i^2 + \sum y_i^2 - \sum x_i \cdot y_i}$

РЕЗЮМЕ

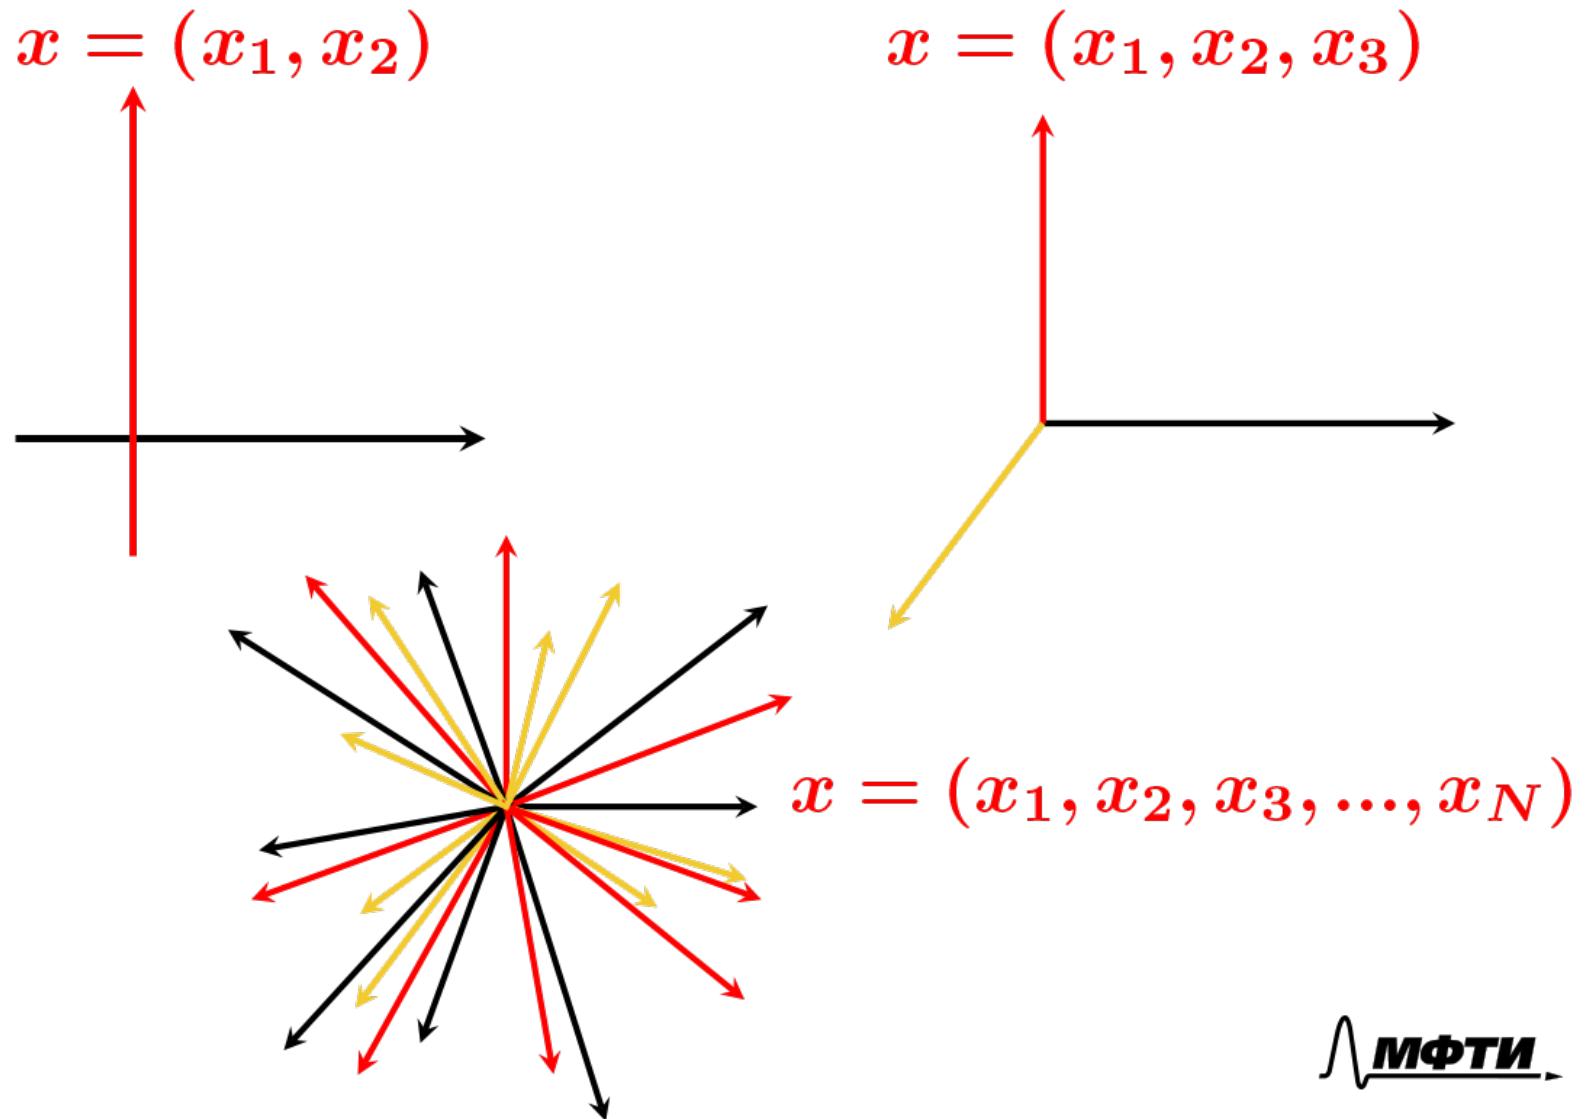
- › Можно придумать множество разных метрик
- › Чтобы понять, какая метрика лучше подходит в задаче, нужно просто попробовать разные
- › Некоторые метрики и функции близости часто используются в задачах из какой-то конкретной области, но все равно полезно экспериментировать

ПРОКЛЯТИЕ РАЗМЕРНОСТИ

РОЛЬ РАССТОЯНИЯ В МЕТРИЧЕСКИХ МЕТОДАХ



РОЛЬ РАССТОЯНИЯ В МЕТРИЧЕСКИХ МЕТОДАХ



РАССТОЯНИЕ В ПРОСТРАНСТВЕ ВЫСОКОЙ РАЗМЕРНОСТИ

- › Нет ли чего-то необычного в свойствах расстояния в пространствах высокой размерности?

ИДЕЯ 1: НЕБОЛЬШИЕ ОТЛИЧИЯ В БОЛЬШОМ ЧИСЛЕ КООРДИНАТ

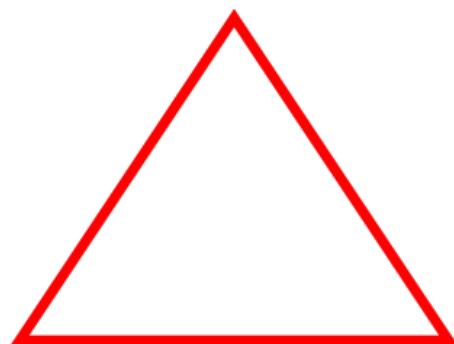
$$x_1 = (a_1, a_2, \dots, a_N)$$

$$x_2 = (a_1 + \varepsilon, a_2 + \varepsilon, \dots, a_N + \varepsilon)$$

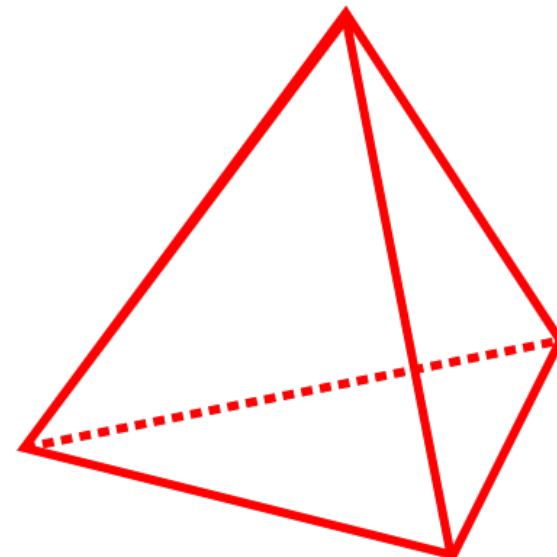
$$x_3 = (a_1, a_2 + \Delta, a_3, \dots, a_N)$$

ИДЕЯ 2: ПОЧТИ ОДИНАКОВЫЕ РАССТОЯНИЯ

Треугольник



Тетраэдр



В N -мерном пространстве — до $N + 1$ равноудалённой точки

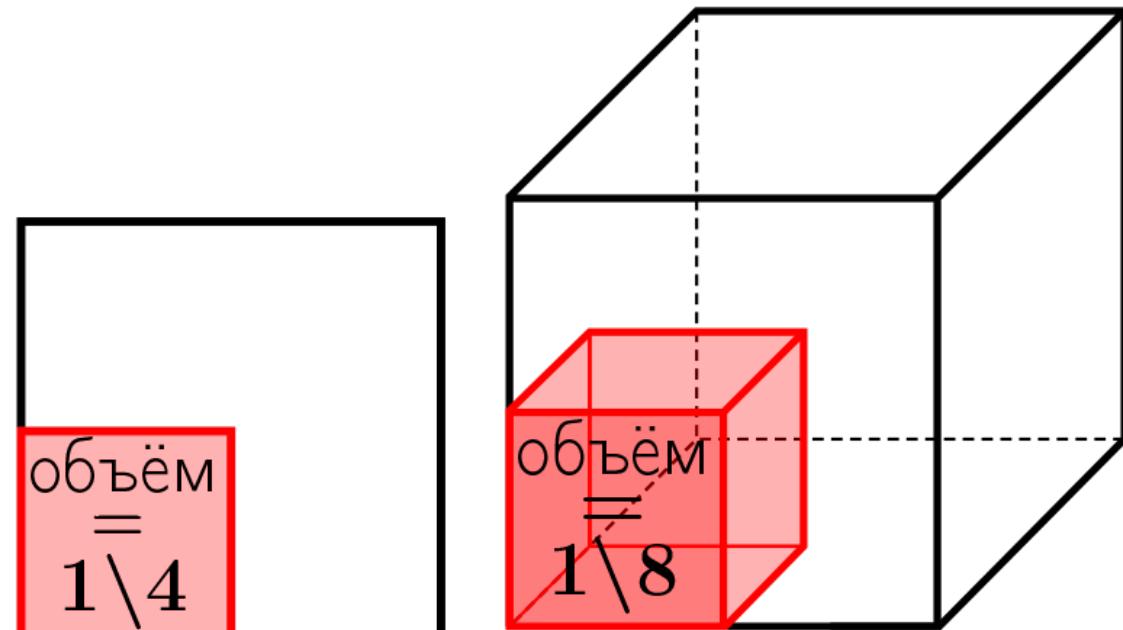
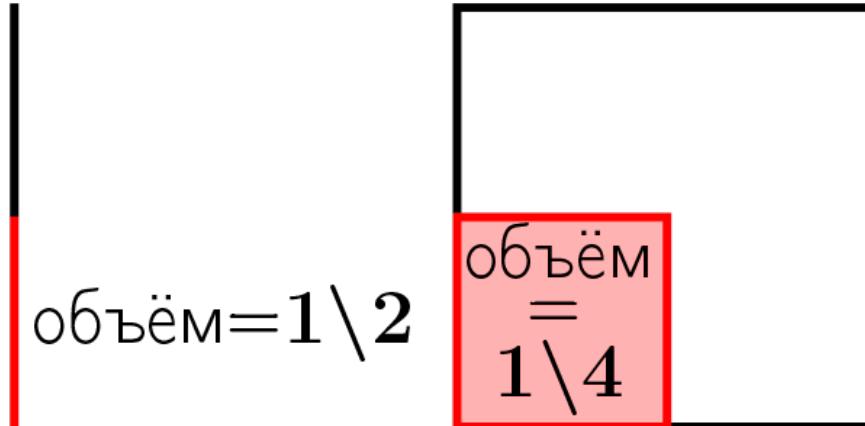
ИДЕЯ 3: ЭКСПОНЕНЦИАЛЬНЫЙ РОСТ НЕОБХОДИМЫХ ДАННЫХ

- › Рассмотрим векторы размерности N из бинарных признаков:

$$X = (0, 0, 1, 0, 1, 1, \dots, 1)$$

- › Всевозможных комбинаций значений признаков — 2^N
- › С ростом N экспоненциально увеличивается необходимое количество данных

ПРИМЕР: ВЕРОЯТНОСТЬ ПОПАДАНИЯ В КУБ



ПРИМЕР: ВЕРОЯТНОСТЬ ПОПАДАНИЯ В КУБ

- › Куб с длиной ребра **0.99** будет составлять **0.99^n** часть от объема единичного куба

$$\lim_{n \rightarrow \infty} 0.99^n = 0$$

РЕЗЮМЕ

- › Расстояние в пространствах высокой размерности
- › Рост необходимого объёма данных
- › Примерно одинаковое расстояние между большинством пар объектов
- › Проклятие размерности

РЕКОМЕНДАЦИИ ФИЛЬМОВ С ПОМОЩЬЮ KNN

ЗАДАЧА

- › Есть известные оценки, которые пользователи поставили уже просмотренным фильмам
- › Нужно:
 - ▶ Спрогнозировать оценки, которые поставили бы пользователи другим фильмам
 - ▶ Порекомендовать пользователям то, что им больше понравится

ЗАДАЧА

	Пила	Улица Вязов	Ванильное небо	1+1
Маша	5	4	1	2
Юля		5	2	
Вова			3	5
Коля	3		4	5
Петя				4
Ваня		5	3	3

ЗАДАЧА

	Пила	Улица Вязов	Ванильное небо	1+1
Маша	5	4	1	2
Юля		5	2	?
Вова			3	5
Коля	3		4	5
Петя				4
Ваня		5	3	3

USER-BASED

	Пила	Улица Вязов	Ванильное небо	1+1
Маша	5	4	1	2
Юля		5	2	
Вова			3	5
Коля			4	5
Петя				4
Ваня	5	3	3	

USER-BASED

	Пила	Улица Вязов	Ванильное небо	1+1
Маша	5	4	1	2
Юля		5	2	?
Вова			3	5
Коля	3		4	5
Петя				4
Ваня		5	3	3

ITEM-BASED

	Пила	Улица Вязов	Ванильное небо	1+1
Маша	5	4	1	2
Юля		5	2	?
Вова			3	5
Коля	3		4	5
Петя				4
Ваня		5	3	3

ПОХОЖЕСТЬ ПОЛЬЗОВАТЕЛЕЙ

			<i>a</i>	
	Пила	Улица Вязов	Ванильное небо	1+1
Masha	5	4	1	2
Юля		5	2	
Вова			3	5
i Коля	3		<i>r_{i,a}</i>	5
Петя				4
j Ваня		5	<i>r_{j,a}</i>	3

$$\bar{r}_i = \frac{3+r_{i,a}+5}{3}$$

$$\bar{r}_j = \frac{5+r_{j,a}+3}{3}$$

ПОХОЖЕСТЬ ПОЛЬЗОВАТЕЛЕЙ

	<i>a</i>			
	Пила	Улица Вязов	Ванильное небо	1+1
Маша	5	4	1	2
Юля		5	2	
Вова			3	5
<i>i</i> Коля	3		$r_{i,a}$	5
Петя				4
<i>j</i> Ваня		5	$r_{j,a}$	3

$$\bar{r}_i = \frac{3 + r_{i,a} + 5}{3}$$

$$\bar{r}_j = \frac{5 + r_{j,a} + 3}{3}$$

ПОХОЖЕСТЬ ПОЛЬЗОВАТЕЛЕЙ

	Пила	Улица Вязов	Ванильное небо	$1+1$
Маша	5	4	1	2
Юля		5	2	
Вова			3	5
i	Коля	3		$r_{i,a}$
	Петя			4
j	Ваня	5		$r_{j,a}$
				3

$$w_{i,j} = \frac{\sum_a (r_{i,a} - \bar{r}_i)(r_{j,a} - \bar{r}_j)}{\sqrt{\sum_a (r_{i,a} - \bar{r}_i)^2} \sqrt{\sum_a (r_{j,a} - \bar{r}_j)^2}} \nearrow \text{МФТИ}.$$

ПОХОЖЕСТЬ ПОЛЬЗОВАТЕЛЕЙ

$$w_{i,j} = \frac{\sum_a (r_{i,a} - \bar{r}_i)(r_{j,a} - \bar{r}_j)}{\sqrt{\sum_a (r_{i,a} - \bar{r}_i)^2} \sqrt{\sum_a (r_{j,a} - \bar{r}_j)^2}}$$

Можно делать суммирование не по всем фильмам (заменяя каким-то числом пропуски), а только по тем, которые посмотрели и i -тый и j -тый пользователи

ПОХОЖЕСТЬ ПОЛЬЗОВАТЕЛЕЙ

$$w_{i,j} = \frac{\sum_a r_{i,a} r_{j,a}}{\sqrt{\sum_a r_{i,a}^2} \sqrt{\sum_a r_{j,a}^2}}$$

ПРОГНОЗИРОВАНИЕ РЕЙТИНГА

$$\hat{r}_{i,a} = \bar{r}_i + \frac{\sum_j (r_{j,a} - \bar{r}_j) w_{i,j}}{\sum_j |w_{i,j}|}$$

ПРОГНОЗИРОВАНИЕ РЕЙТИНГА

$$\hat{r}_{i,a} = \bar{r}_i + \frac{\sum_j (r_{j,a} - \bar{r}_j) w_{i,j}}{\sum_j |w_{i,j}|}$$

ПРОГНОЗИРОВАНИЕ РЕЙТИНГА

$$\hat{r}_{i,a} = \bar{r}_i + \frac{\sum_j (r_{j,a} - \bar{r}_j) w_{i,j}}{\sum_j |w_{i,j}|}$$

$$\hat{r}_{i,a} = \bar{r}_i + \frac{\sum_{j \in k\text{NN}(i)} (r_{j,a} - \bar{r}_j) w_{i,j}}{\sum_{j \in k\text{NN}(i)} |w_{i,j}|}$$

РЕЗЮМЕ

- › kNN — не только для классификации и регрессии
- › Другие задачи тоже могут легко сводиться к той же идее

МЕТОД ОПОРНЫХ ВЕКТОРОВ (SVM)

МЕТОД ОПОРНЫХ ВЕКТОРОВ

- › Линейный классификатор:

$$a(x) = \text{sign}(\langle w, x \rangle - w_0)$$

- › Использующий кусочно-линейную функцию потерь и $L2$ -регуляризатор:

$$\sum_{i=1}^l L(M_i) + \gamma \|w\|^2 \rightarrow \min_w$$



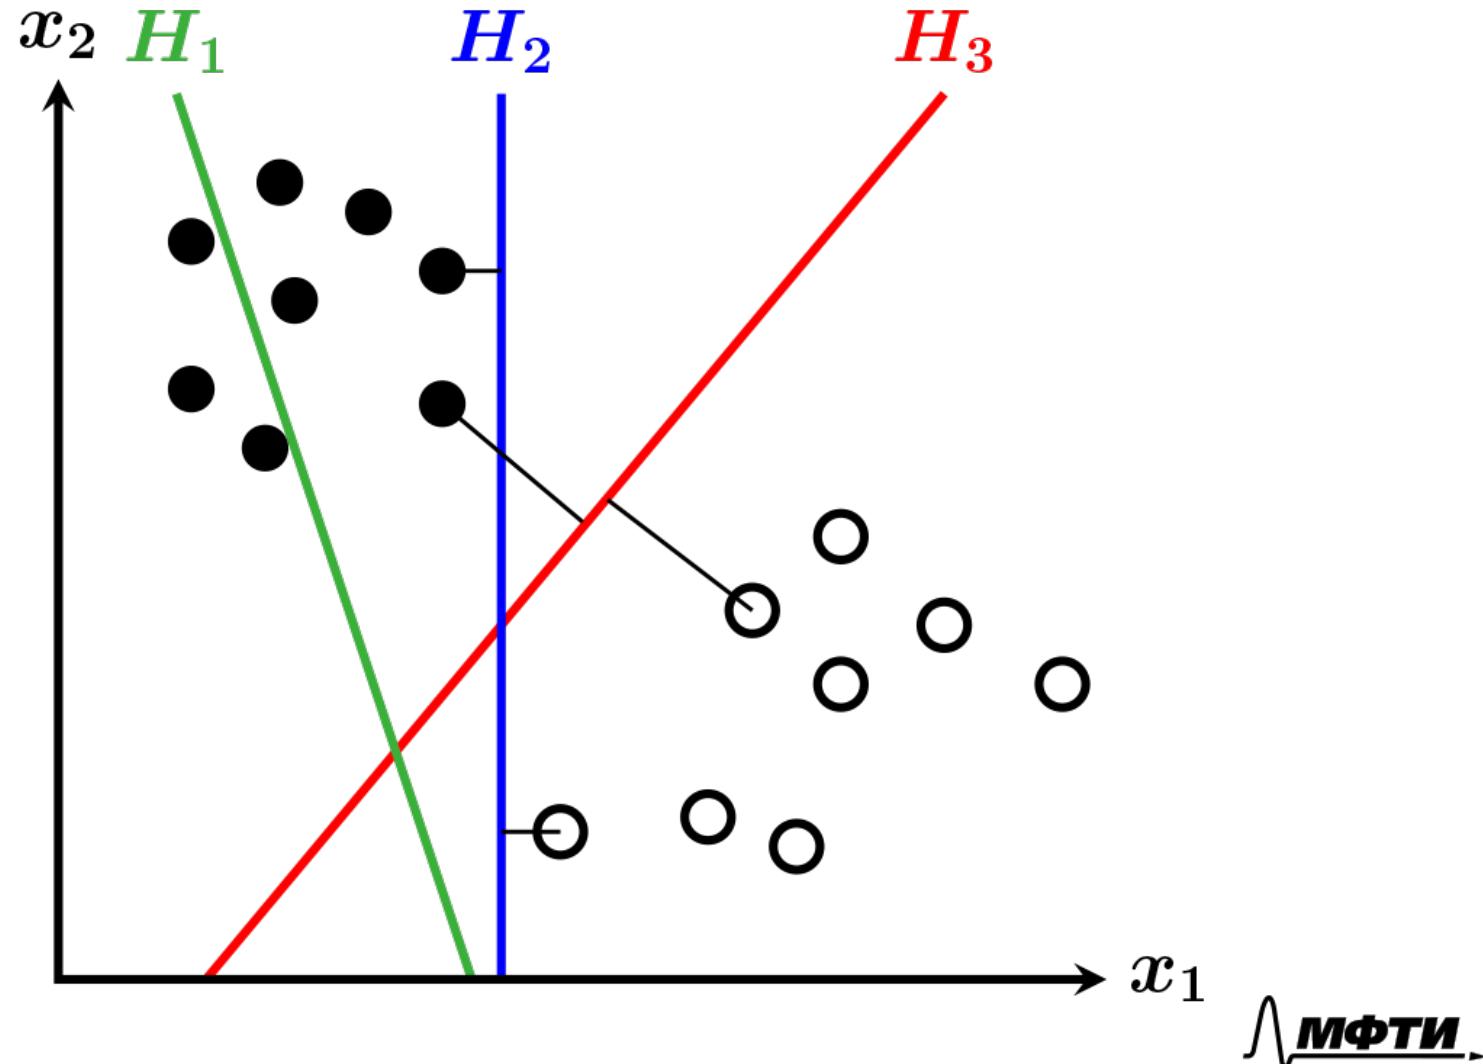
функция потерь

квадратичный регуляризатор

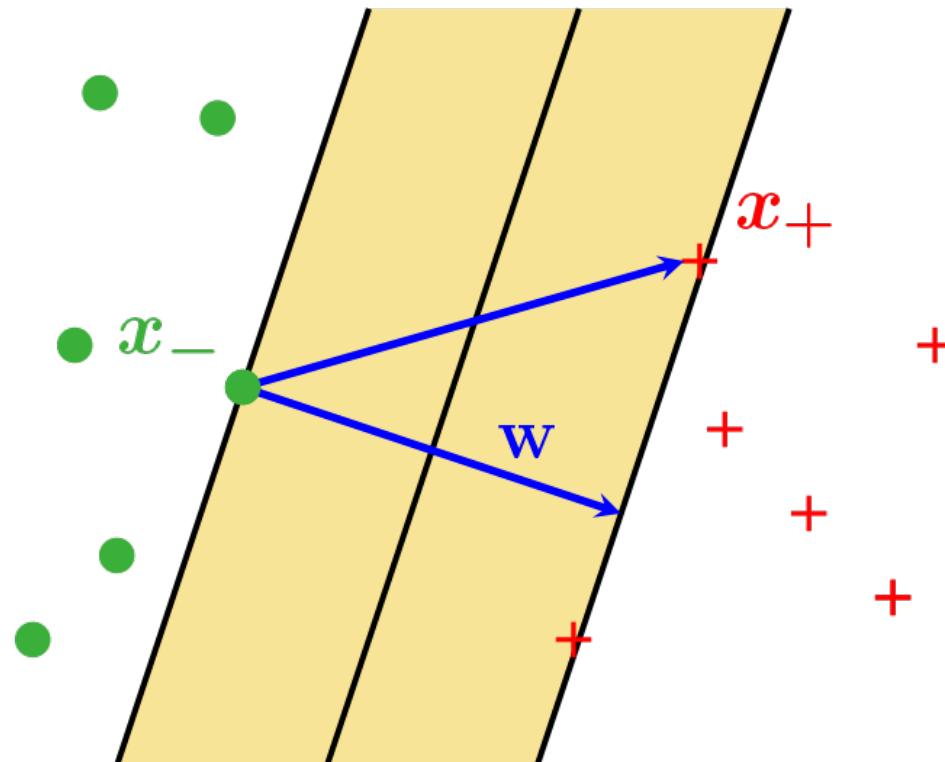
- › Кусочно-линейная функция потерь:

$$L(M_i) = \max\{0, 1 - M_i\} = (1 - M_i)_+$$

ПОСТРОЕНИЕ РАЗДЕЛЯЮЩЕЙ ГИПЕРПЛОСКОСТИ

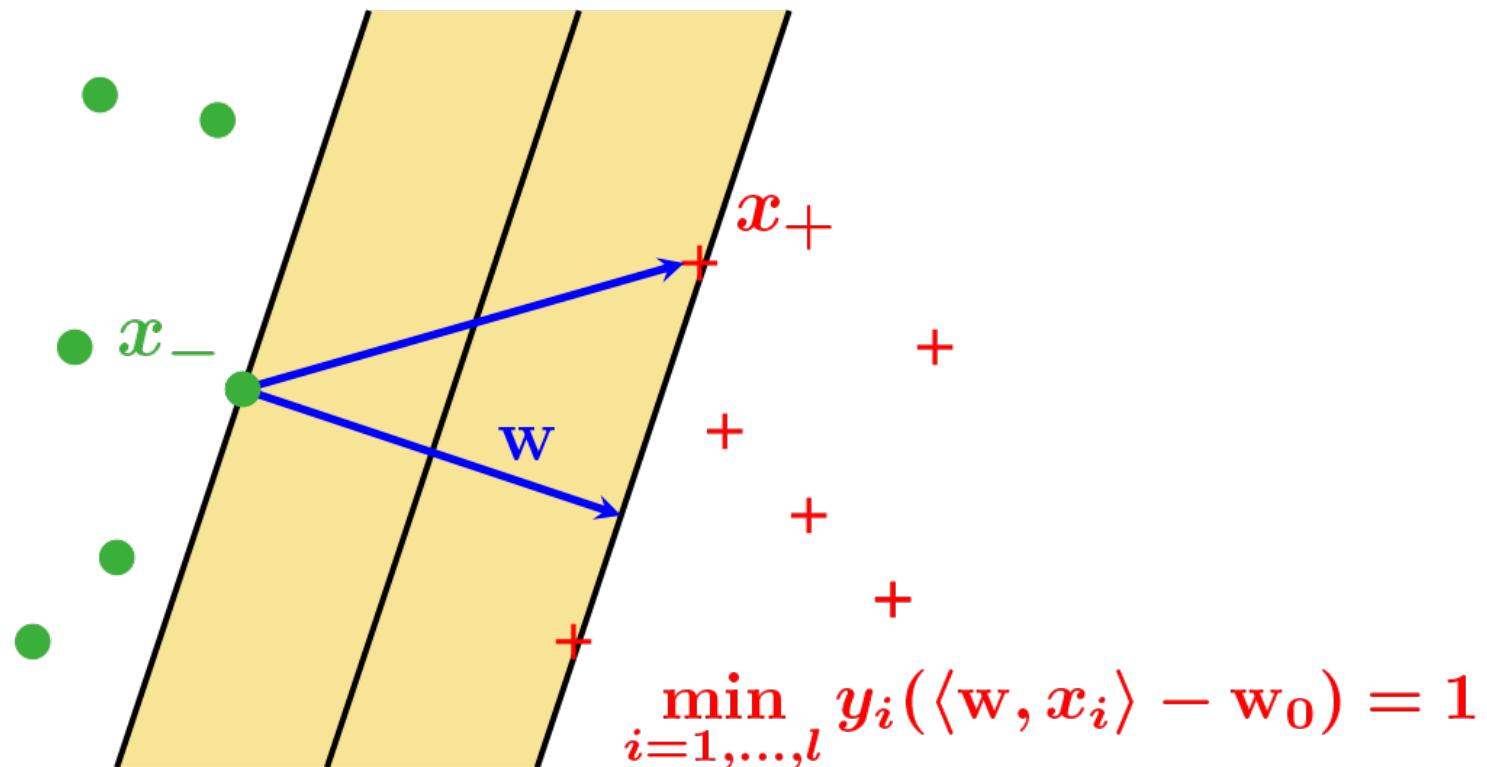


РАЗДЕЛЯЮЩАЯ ПОЛОСА



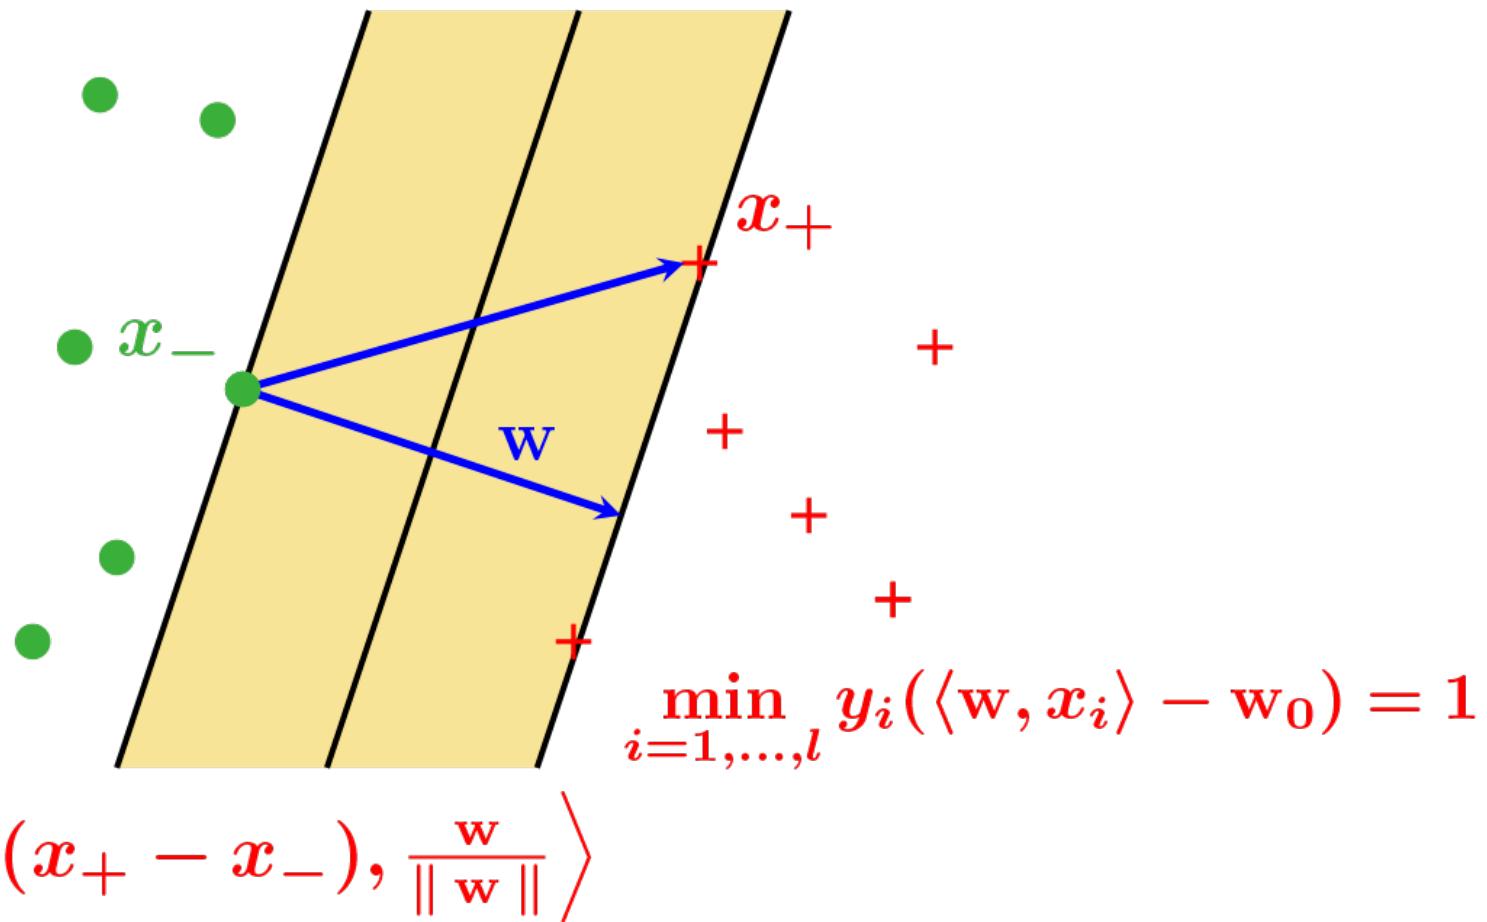
$$a(x) = \text{sign} \left(\sum_{j=1}^n w_j x^j - w_0 \right) = \text{sign} (\langle w, x \rangle - w_0)$$

РАЗДЕЛЯЮЩАЯ ПОЛОСА

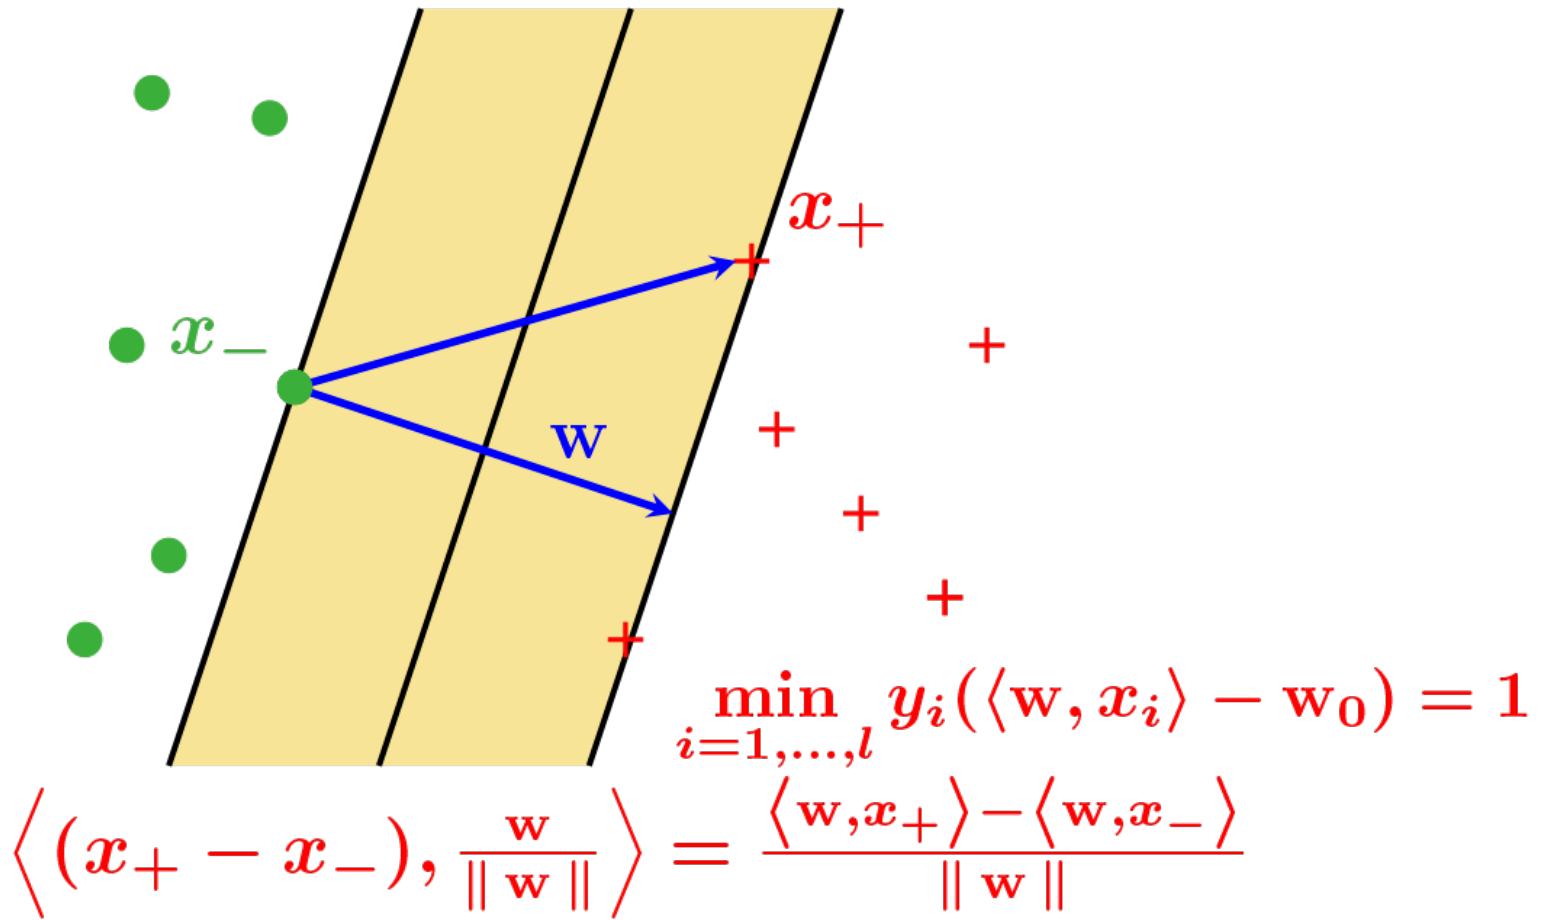


$$a(x) = \text{sign} \left(\sum_{j=1}^n w_j x^j - w_0 \right) = \text{sign} (\langle w, x \rangle - w_0)$$

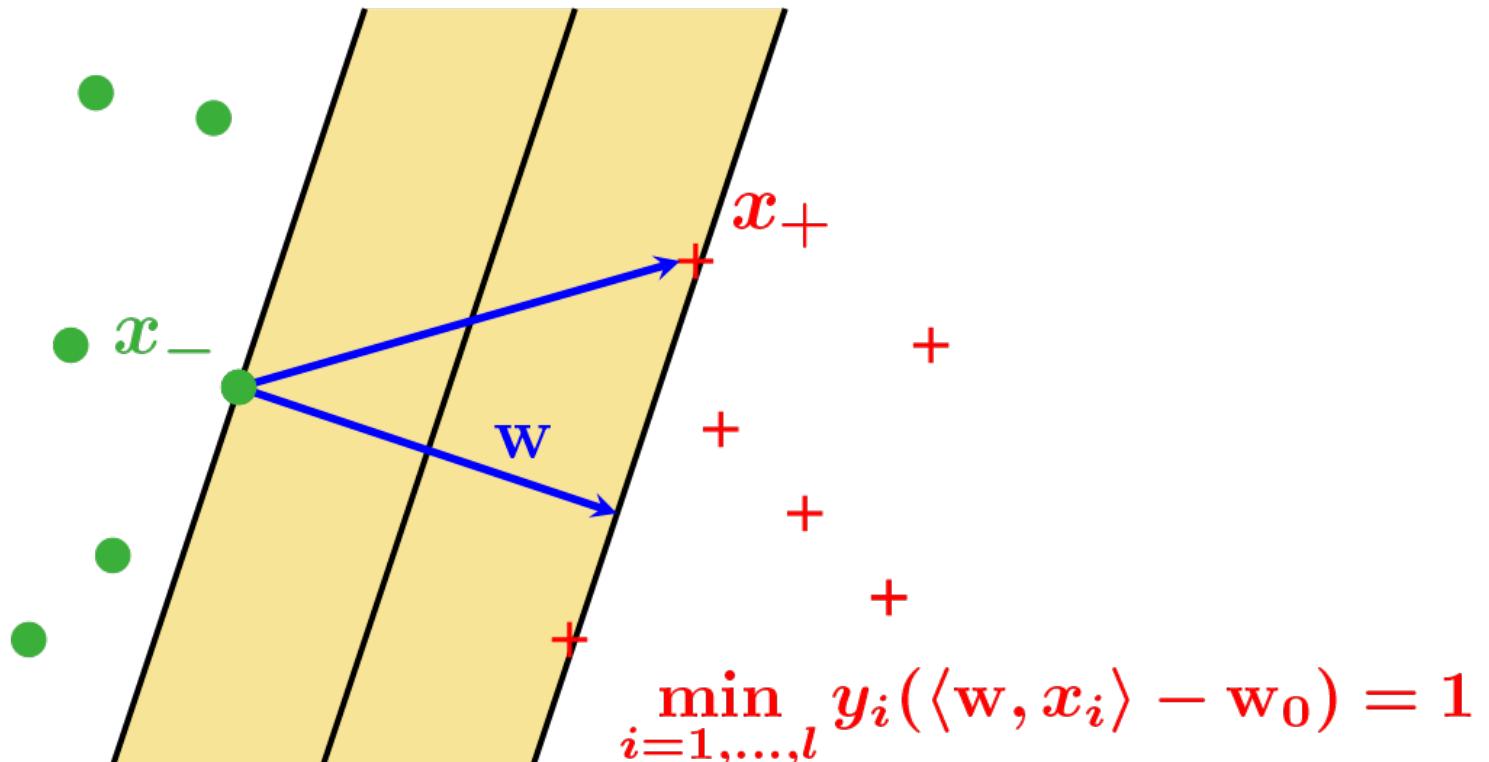
ШИРИНА РАЗДЕЛЯЮЩЕЙ ПОЛОСЫ



ШИРИНА РАЗДЕЛЯЮЩЕЙ ПОЛОСЫ



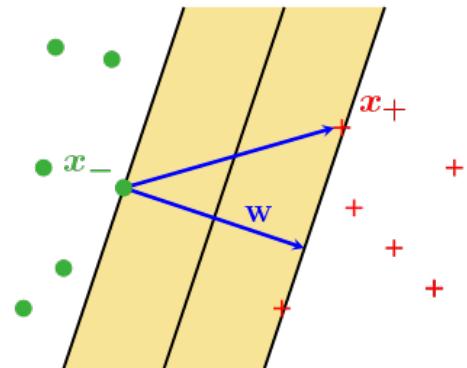
ШИРИНА РАЗДЕЛЯЮЩЕЙ ПОЛОСЫ



$$\left\langle (x_+ - x_-), \frac{w}{\|w\|} \right\rangle = \frac{\langle w, x_+ \rangle - \langle w, x_- \rangle}{\|w\|} =$$

$$= \frac{(w_0 + 1) - (w_0 - 1)}{\|w\|} = \frac{2}{\|w\|}$$

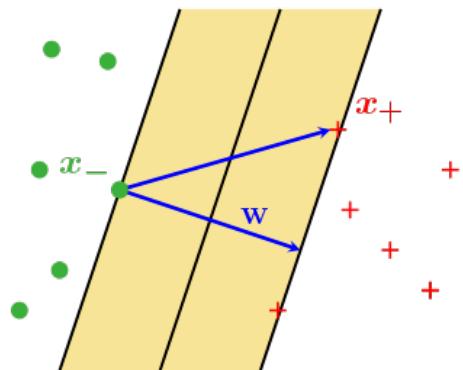
ШИРИНА РАЗДЕЛЯЮЩЕЙ ПОЛОСЫ



$$\min_{i=1,\dots,l} y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle - \mathbf{w}_0) = 1$$

$$\begin{aligned}\left\langle (x_+ - x_-), \frac{\mathbf{w}}{\|\mathbf{w}\|} \right\rangle &= \frac{\langle \mathbf{w}, x_+ \rangle - \langle \mathbf{w}, x_- \rangle}{\|\mathbf{w}\|} = \\ &= \frac{(\mathbf{w}_0 + 1) - (\mathbf{w}_0 - 1)}{\|\mathbf{w}\|} = \frac{2}{\|\mathbf{w}\|}\end{aligned}$$

МАКСИМИЗАЦИЯ ЗАЗОРА

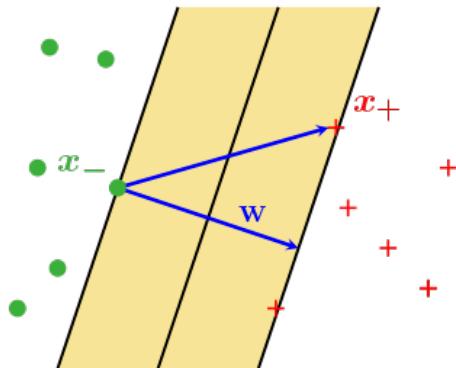


$$\min_{i=1,\dots,l} y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle - w_0) = 1$$

$$\begin{aligned} \left\langle (x_+ - x_-), \frac{\mathbf{w}}{\|\mathbf{w}\|} \right\rangle &= \frac{\langle \mathbf{w}, x_+ \rangle - \langle \mathbf{w}, x_- \rangle}{\|\mathbf{w}\|} = \\ &= \frac{(w_0 + 1) - (w_0 - 1)}{\|\mathbf{w}\|} = \frac{2}{\|\mathbf{w}\|} \end{aligned}$$

$$\begin{cases} \langle \mathbf{w}, \mathbf{w} \rangle \rightarrow \min \\ y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle - w_0) \geq 1, \quad i = 1, \dots, l \end{cases}$$

Случай линейно неразделимой выборки



$$\begin{cases} \langle \mathbf{w}, \mathbf{w} \rangle \rightarrow \min \\ y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle - w_0) \geq 1, \quad i = 1, \dots, l \end{cases}$$

$$\begin{cases} \frac{1}{2} \langle \mathbf{w}, \mathbf{w} \rangle + C \sum_{i=1}^l \xi_i \rightarrow \min_{\mathbf{w}, w_0, \xi} \\ y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle - w_0) \geq 1 - \xi_i, \quad i = 1, \dots, l \\ \xi_i \geq 0, \quad i = 1, \dots, l \end{cases}$$

ОПТИМИЗИЦИОННАЯ ЗАДАЧА В SVM

$$\begin{cases} \frac{1}{2} \langle w, w \rangle + C \sum_{i=1}^l \xi_i \rightarrow \min_w, w_0, \xi \\ y_i (\langle w, x_i \rangle - w_0) \geq 1 - \xi_i, \quad i = 1, \dots, l \\ \xi_i \geq 0, \quad i = 1, \dots, l \end{cases}$$

Причём здесь линейный классификатор в привычном нам виде?

БЕЗУСЛОВНАЯ ОПТИМИЗАЦИОННАЯ ЗАДАЧА В SVM

$$\begin{cases} \frac{1}{2} \langle \mathbf{w}, \mathbf{w} \rangle + C \sum_{i=1}^l \xi_i \rightarrow \min_{\mathbf{w}, \mathbf{w}_0, \xi} \\ y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle - \mathbf{w}_0) \geq 1 - \xi_i, \quad i = 1, \dots, l \\ \xi_i \geq 0, \quad i = 1, \dots, l \end{cases}$$

Напоминание:

$M_i = y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle - \mathbf{w}_0)$
отступ на i -том объекте

БЕЗУСЛОВНАЯ ОПТИМИЗАЦИОННАЯ ЗАДАЧА В SVM

$$\begin{cases} \frac{1}{2} \langle \mathbf{w}, \mathbf{w} \rangle + C \sum_{i=1}^l \xi_i \rightarrow \min_{\mathbf{w}, w_0, \xi} \\ y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle - w_0) \geq 1 - \xi_i, \quad i = 1, \dots, l \\ \xi_i \geq 0, \quad i = 1, \dots, l \\ \xi_i \geq 1 - M_i \\ \sum_{i=1}^l \xi_i \rightarrow \min \end{cases}$$

Напоминание:

$M_i = y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle - w_0)$
отступ на i -том объекте

БЕЗУСЛОВНАЯ ОПТИМИЗАЦИОННАЯ ЗАДАЧА В SVM

$$\begin{cases} \frac{1}{2} \langle \mathbf{w}, \mathbf{w} \rangle + C \sum_{i=1}^l \xi_i \rightarrow \min_{\mathbf{w}, \mathbf{w}_0, \xi} \\ y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle - \mathbf{w}_0) \geq 1 - \xi_i, \quad i = 1, \dots, l \\ \xi_i \geq 0, \quad i = 1, \dots, l \\ \xi_i \geq 0 \\ \xi_i \geq 1 - M_i \\ \sum_{i=1}^l \xi_i \rightarrow \min \end{cases}$$

Напоминание:
 $M_i = y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle - \mathbf{w}_0)$
отступ на i -том объекте
 $\Rightarrow \xi_i = \max\{0, 1 - M_i\} = (1 - M_i)_+$

БЕЗУСЛОВНАЯ ОПТИМИЗАЦИОННАЯ ЗАДАЧА В SVM

$$\begin{cases} \frac{1}{2} \langle \mathbf{w}, \mathbf{w} \rangle + C \sum_{i=1}^l \xi_i \rightarrow \min_{\mathbf{w}, \mathbf{w}_0, \xi} \\ y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle - \mathbf{w}_0) \geq 1 - \xi_i, \quad i = 1, \dots, l \\ \xi_i \geq 0, \quad i = 1, \dots, l \\ \xi_i \geq 0 \\ \xi_i \geq 1 - M_i \\ \sum_{i=1}^l \xi_i \rightarrow \min \end{cases}$$

$\Rightarrow \xi_i = \max\{0, 1 - M_i\} = (1 - M_i)_+$

$$Q(\mathbf{w}, \mathbf{w}_0) = \sum_{i=1}^l (1 - M_i(\mathbf{w}, \mathbf{w}_0))_+ + \frac{1}{2C} \|\mathbf{w}\|^2 \rightarrow \min_{\mathbf{w}, \mathbf{w}_0}$$

БЕЗУСЛОВНАЯ ОПТИМИЗАЦИОННАЯ ЗАДАЧА В SVM

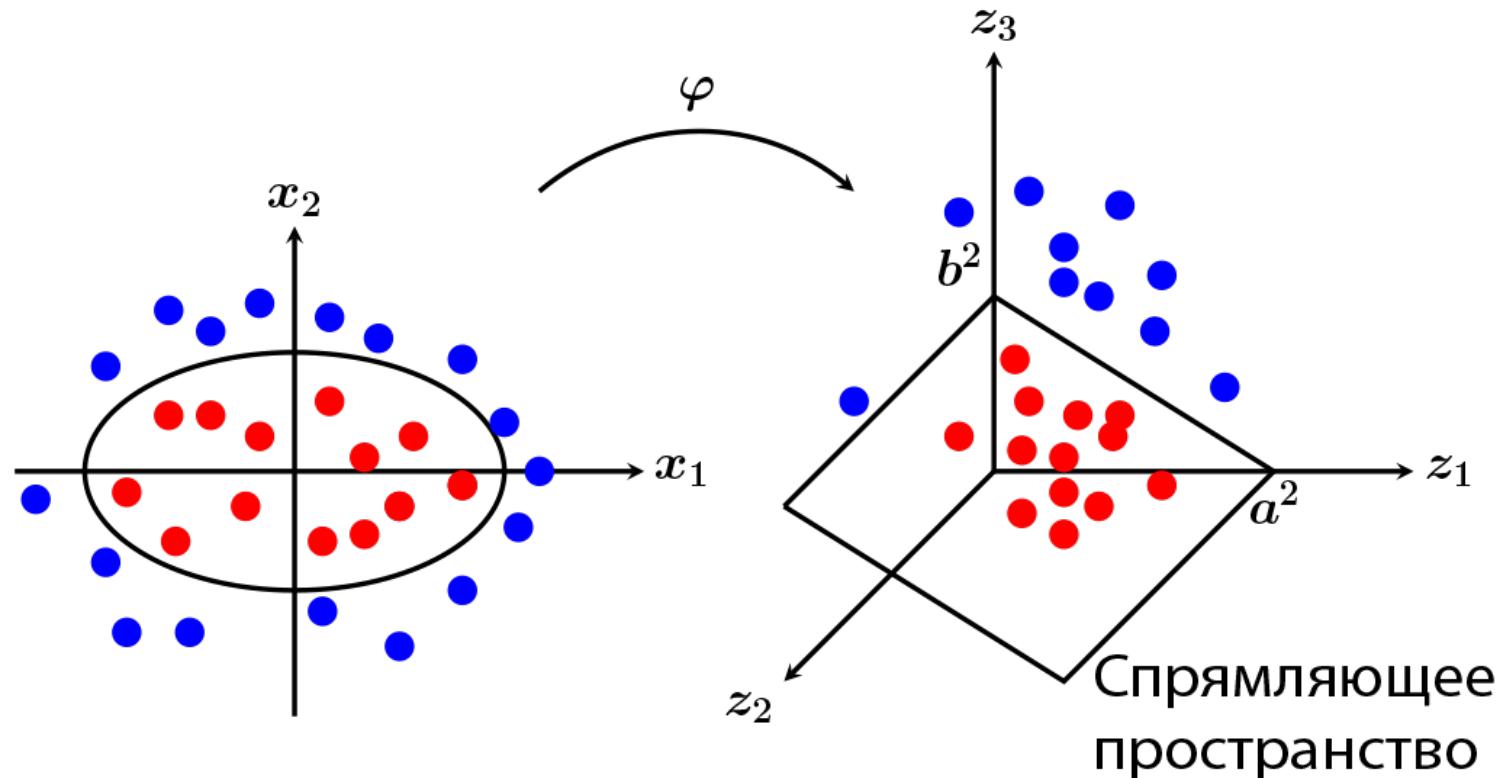
$$Q(\mathbf{w}, \mathbf{w}_0) = \sum_{i=1}^l (1 - M_i(\mathbf{w}, \mathbf{w}_0))_+ + \frac{1}{2C} \|\mathbf{w}\|^2 \rightarrow \min_{\mathbf{w}, \mathbf{w}_0}$$

РЕЗЮМЕ

- › Метод опорных векторов — линейный классификатор с кусочно-линейной функцией потерь (hinge loss) и L_2 -регуляризатором
- › Придуман метод был из соображений максимизации зазора между классами
- › В случае линейно разделимой выборки это означает просто максимизацию ширины разделяющей полосы
- › А в случае линейно неразделимой выборки просто добавляется возможность попадания объектов в полосу и штрафы за это

ЯДРА В МЕТОДЕ ОПОРНЫХ ВЕКТОРОВ

ДОБАВЛЕНИЕ НОВЫХ ПРИЗНАКОВ



$$\varphi : (x_1, x_2) \rightarrow (x_1^2, \sqrt{2}x_1x_2, x_2^2)$$

$$\left(\frac{x_1}{a}\right)^2 + \left(\frac{x_2}{b}\right)^2 = 1 \rightarrow \frac{z_1}{a^2} + \frac{z_3}{b^2} = 1$$

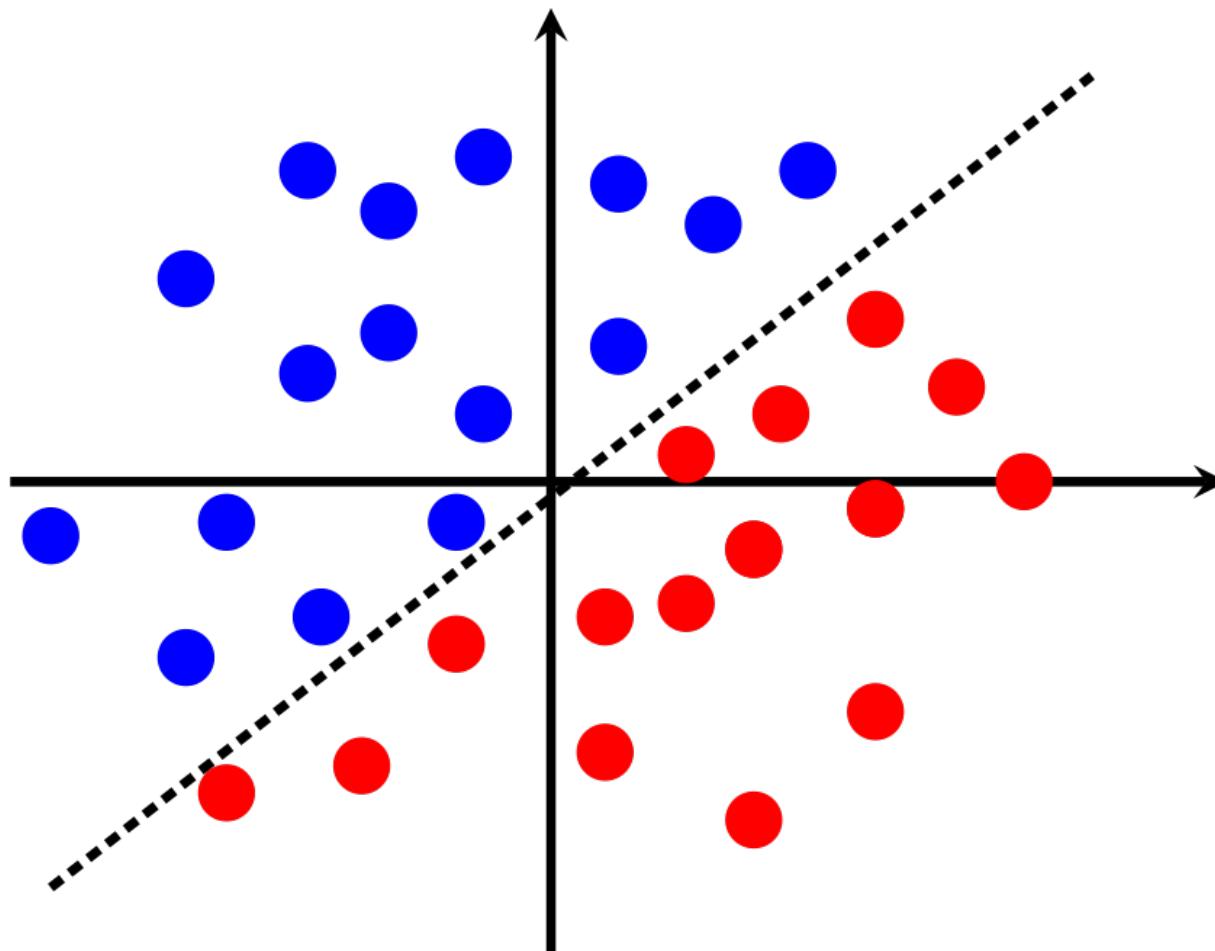
KERNEL TRICK

$$\begin{aligned} x &\mapsto \varphi(x) \\ w &\mapsto \varphi(w) \end{aligned} \Rightarrow \langle w, x \rangle \mapsto \langle \varphi(w), \varphi(x) \rangle$$

Можно не делать преобразование признаков явно, а вместо скалярного произведения $\langle w, x \rangle$ использовать функцию $K(w, x)$, представимую в виде:

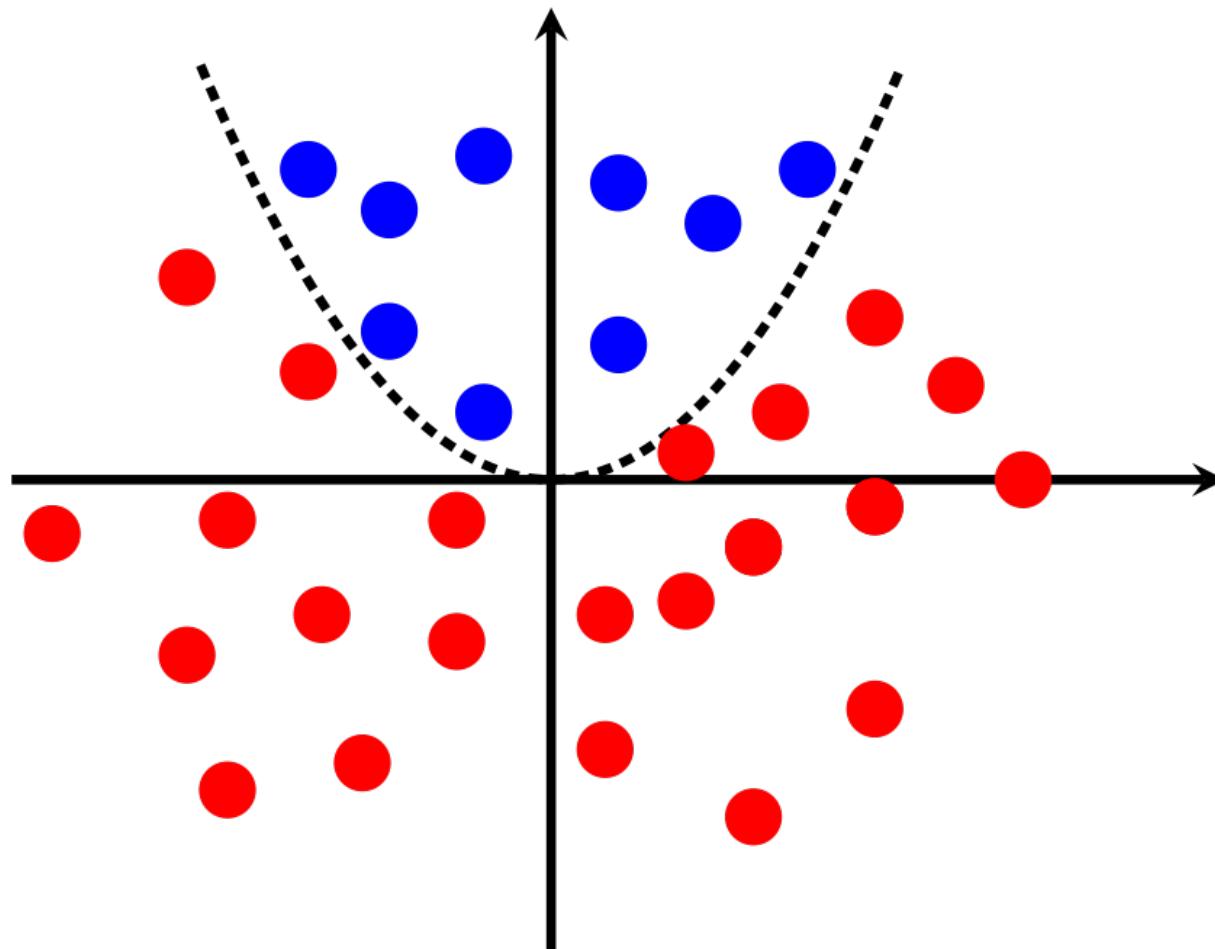
$$K(w, x) = \langle \varphi(w), \varphi(x) \rangle$$

ЛИНЕЙНОЕ ЯДРО



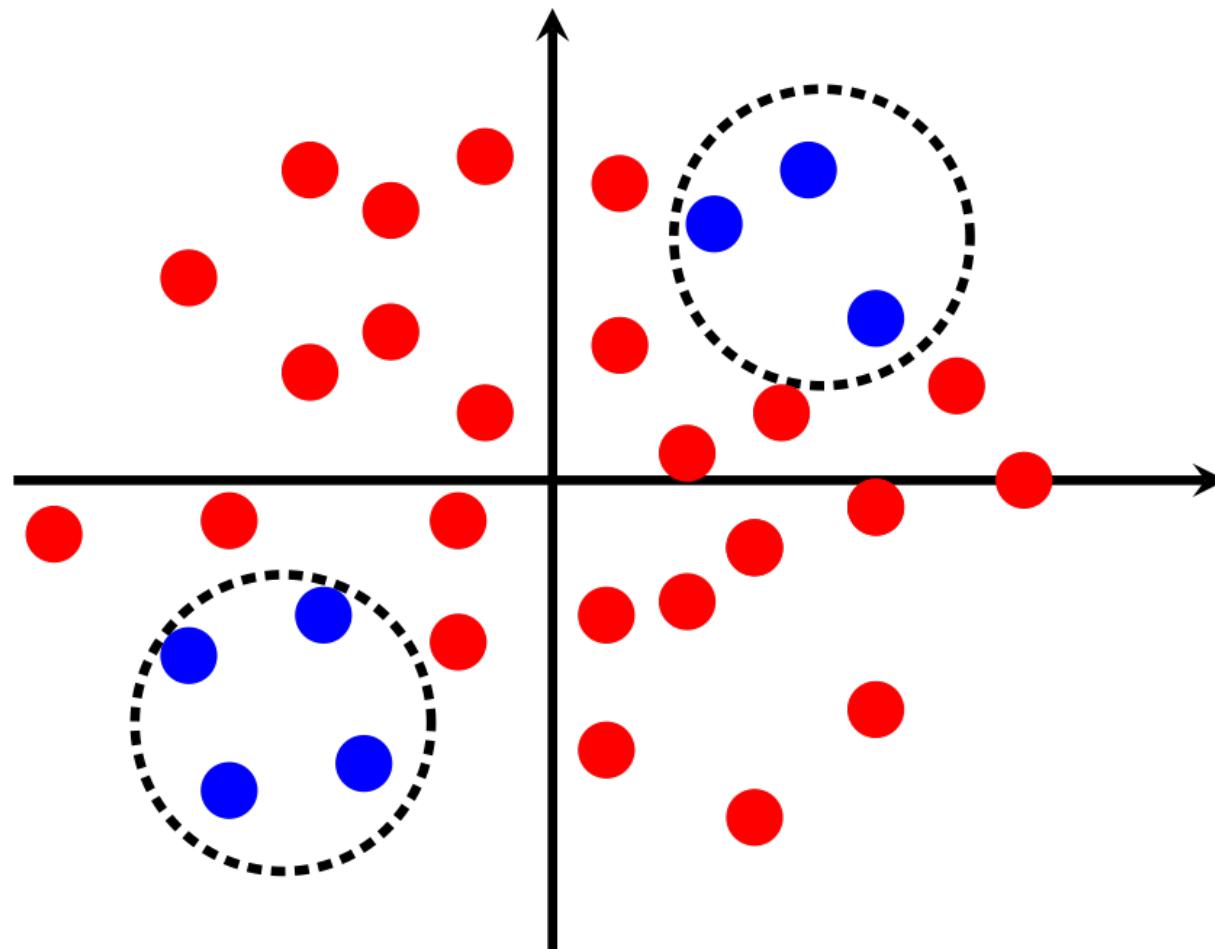
$$K(w, x) = \langle w, x \rangle$$

ПОЛИНОМИАЛЬНОЕ ЯДРО



$$K(w, x) = (\gamma \langle w, x \rangle + r)^d$$

РАДИАЛЬНОЕ ЯДРО



$$K(w, x) = e^{-\gamma \|w - x\|^2}$$

ЯДРА И БИБЛИОТЕКИ

- › LibSVM — можно выбирать ядра
- › LibLinear — только линейное ядро
- › Scikit-learn — обёртка над LibSVM и LibLinear
- › Vowpal Wabbit — только линейное ядро

РЕЗЮМЕ

- › Kernel trick
- › Линейное, полиномиальное и радиальное ядра
- › Библиотеки